



Budapesti Műszaki és Gazdaságtudományi Egyetem
Villamosmérnöki és Informatikai Kar
Mesterséges Intelligencia és Rendszertervezés Tanszék



VIMIAC16 2025/26/I.

Regressziós modellek és neurális hálók

Előadó: Dr. Hullám Gábor



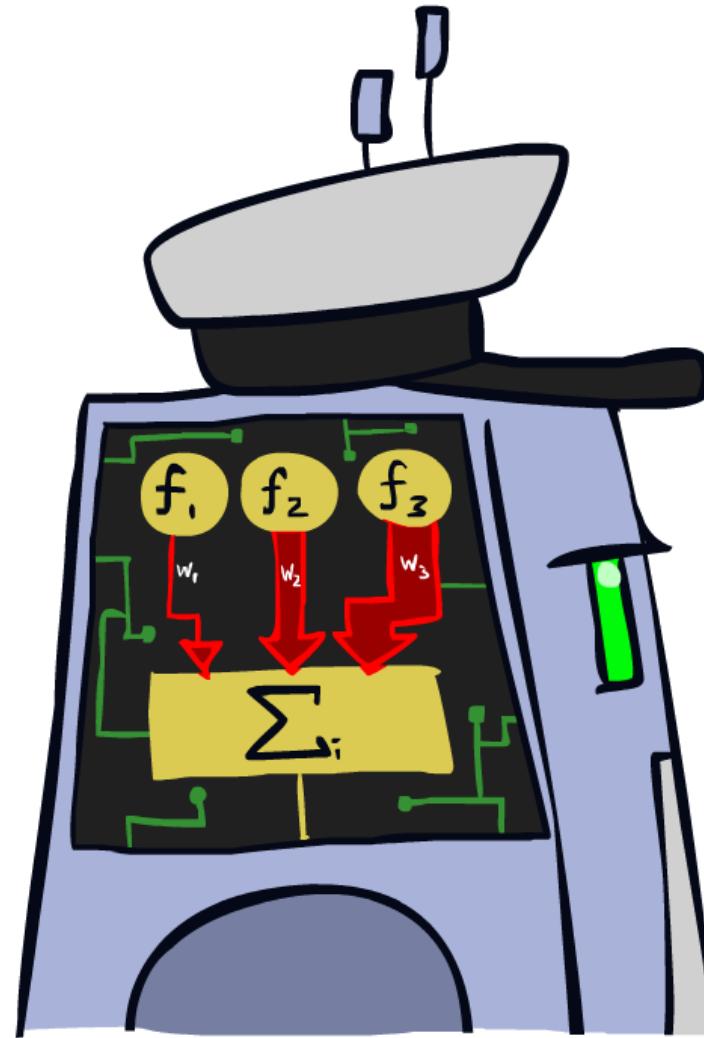


Mesterséges intelligencia előadássorozat

Az előadás diái az AIMA könyvre épülve (<http://aima.cs.berkeley.edu>) készültek a University of California, Berkeley mesterséges intelligencia kurzusának anyagainak felhasználásával (<http://ai.berkeley.edu>).

These slides are based on the AIMA book (<http://aima.cs.berkeley.edu>) and were adapted from the AI course material of University of California, Berkeley (<http://ai.berkeley.edu>).

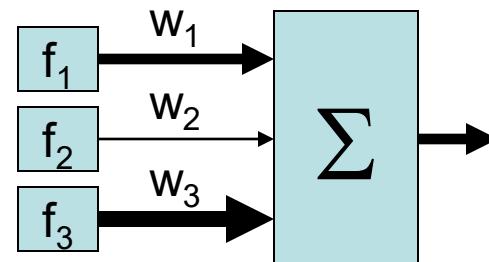
Lineáris modellek



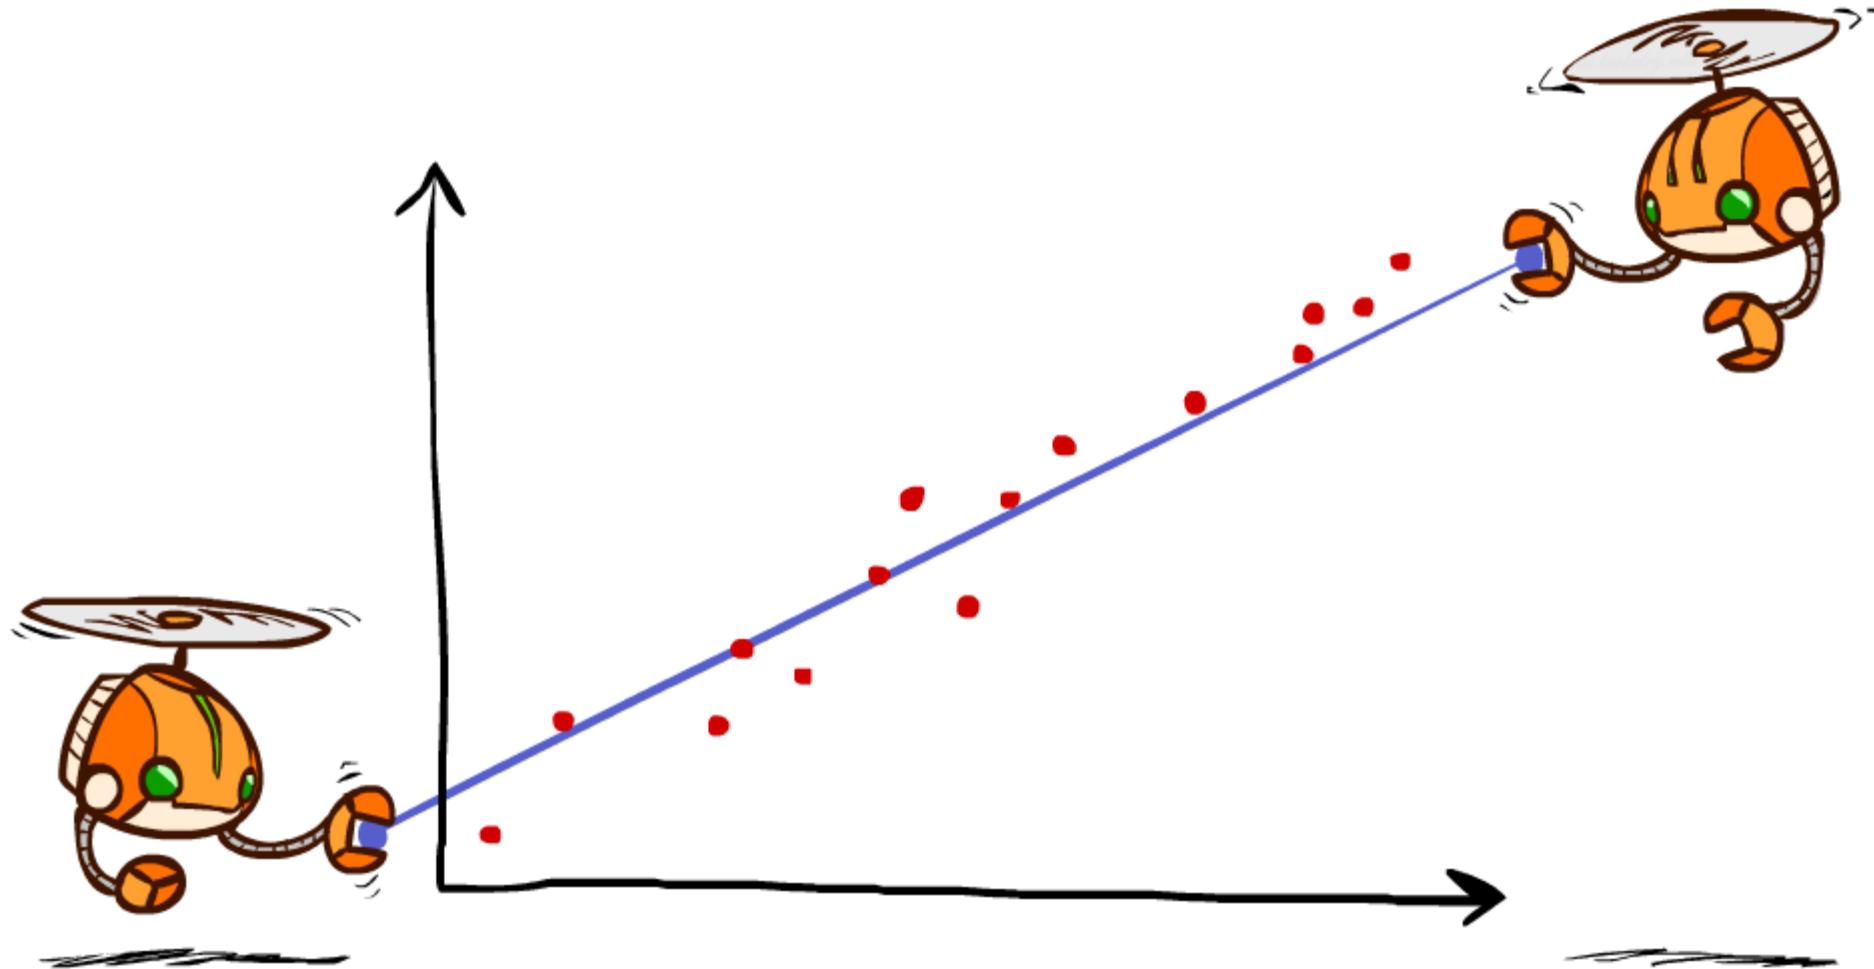
Lineáris modellek

- A bemenetek **változó** (jellemző, feature) értékek
- minden **változónak** van egy **súlya**
- Az összegzett eredmény (lineáris kombináció) a kimenet

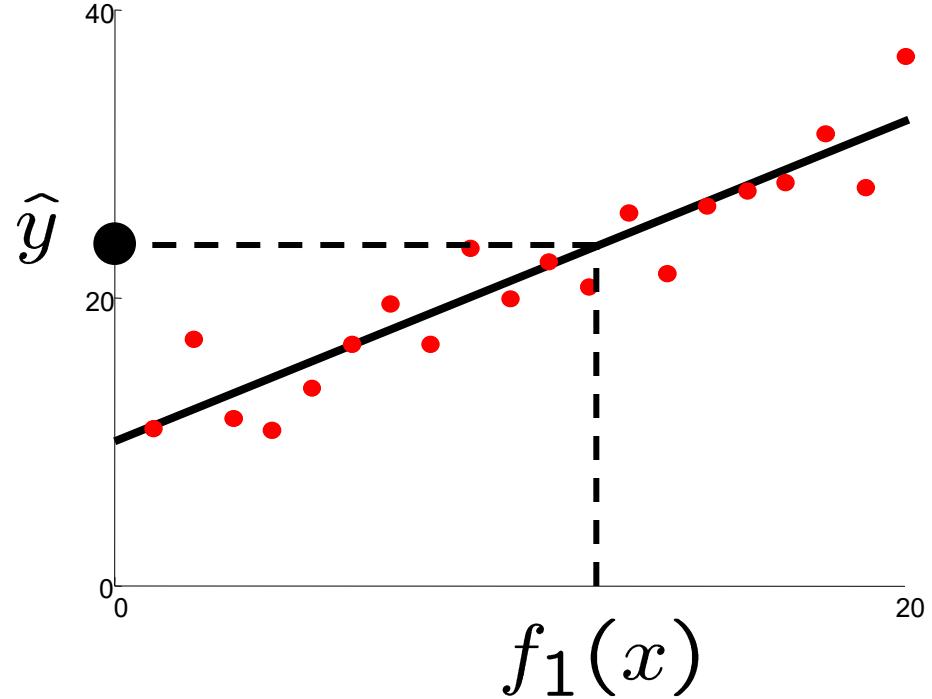
$$y = \sum_i w_i \cdot f_i(x) = w \cdot f(x)$$



Lineáris regresszió

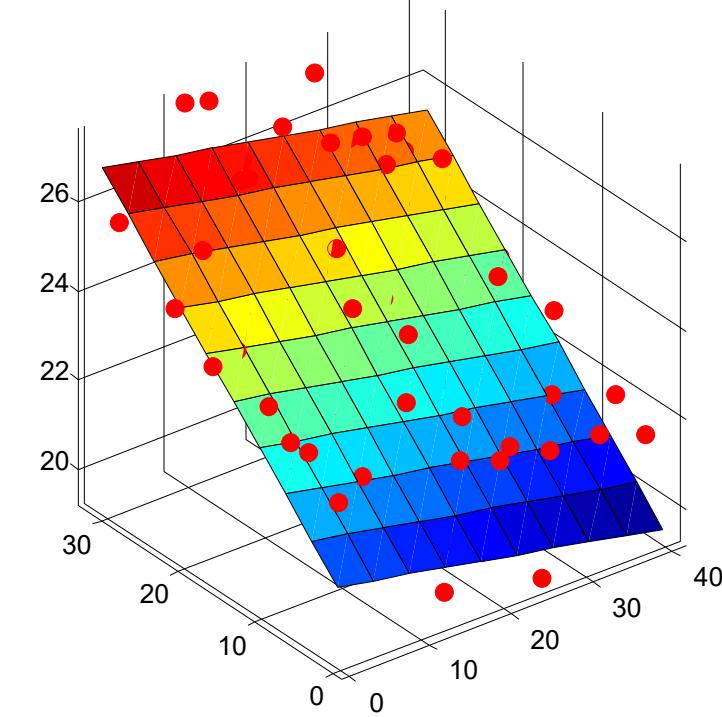


Lineáris közelítés: regresszió



Predikció:

$$\hat{y} = w_0 + w_1 f_1(x)$$

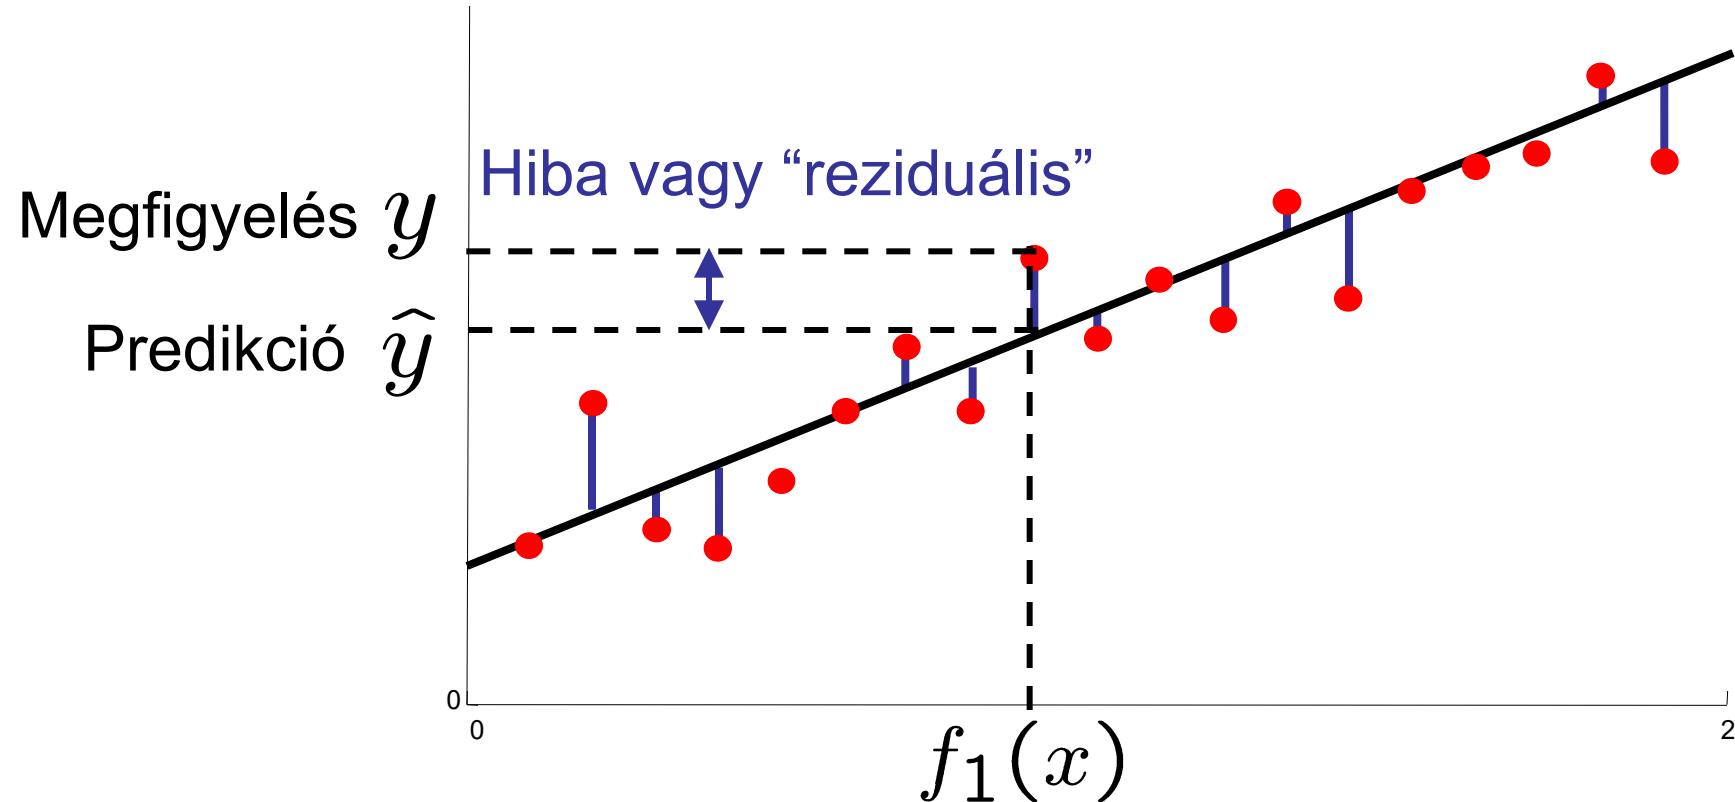


Predikció:

$$\hat{y}_i = w_0 + w_1 f_1(x) + w_2 f_2(x)$$

Optimalizálás: Legkisebb négyzetek (Least Squares)

$$\text{total error} = \sum_i (y_i - \hat{y}_i)^2 = \sum_i \left(y_i - \sum_k w_k f_k(x_i) \right)^2$$



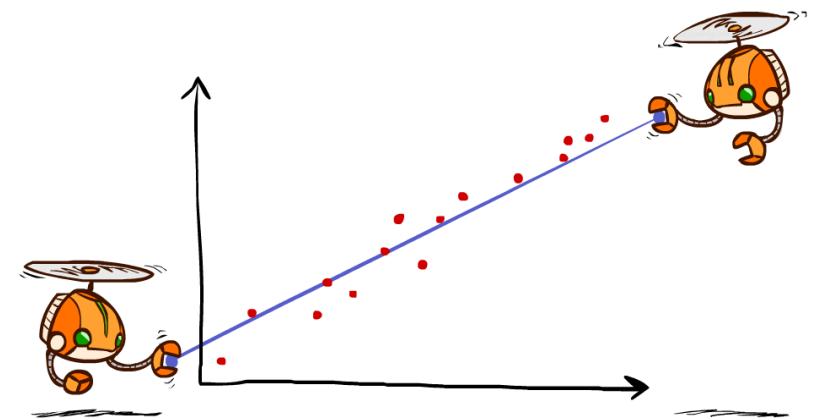
A hiba minimalizálása

Képzeljük el, hogy csak egy **x** pontunk van, **f(x)** jellemzőkkel, **y** célértékkal és **w** súlyokkal:

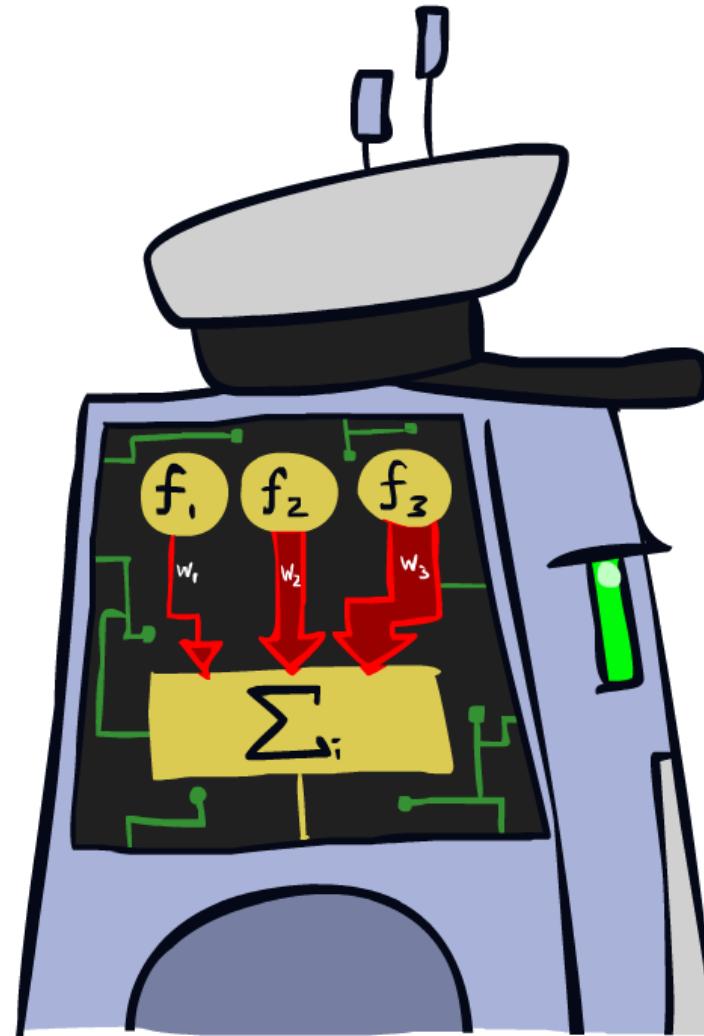
$$\text{error}(w) = \frac{1}{2} \left(y - \sum_k w_k f_k(x) \right)^2$$

$$\frac{\partial \text{error}(w)}{\partial w_m} = - \left(y - \sum_k w_k f_k(x) \right) f_m(x)$$

$$w_m \leftarrow w_m + \alpha \left(y - \sum_k w_k f_k(x) \right) f_m(x)$$



Lineáris osztályozók



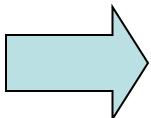
Jellemző vektorok

x

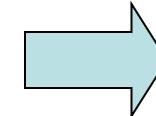
$f(x)$

y

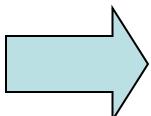
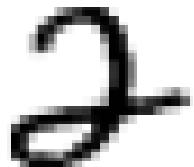
Hello,
Do you want free printr
cartridges? Why pay more
when you can get them
ABSOLUTELY FREE! Just



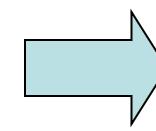
$\begin{Bmatrix} \# \text{ free} & : 2 \\ \text{YOUR_NAME} & : 0 \\ \text{MISSPELLED} & : 2 \\ \text{FROM_FRIEND} & : 0 \\ \dots \end{Bmatrix}$



SPAM
or
+



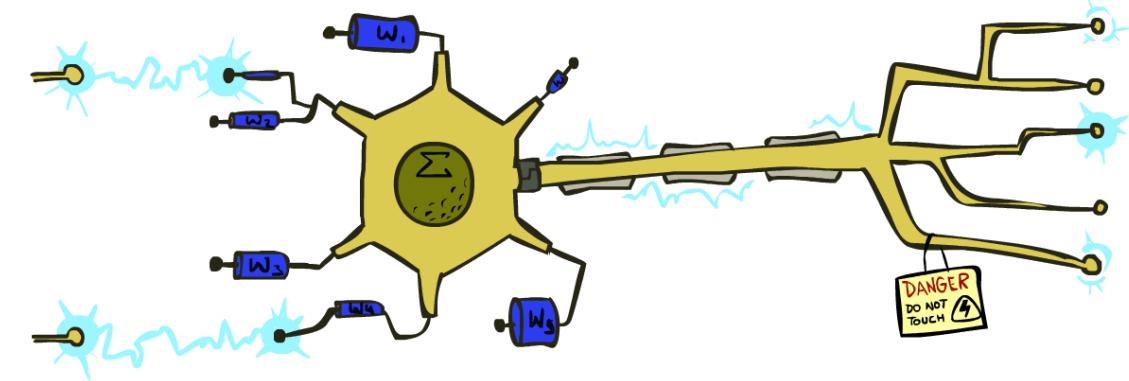
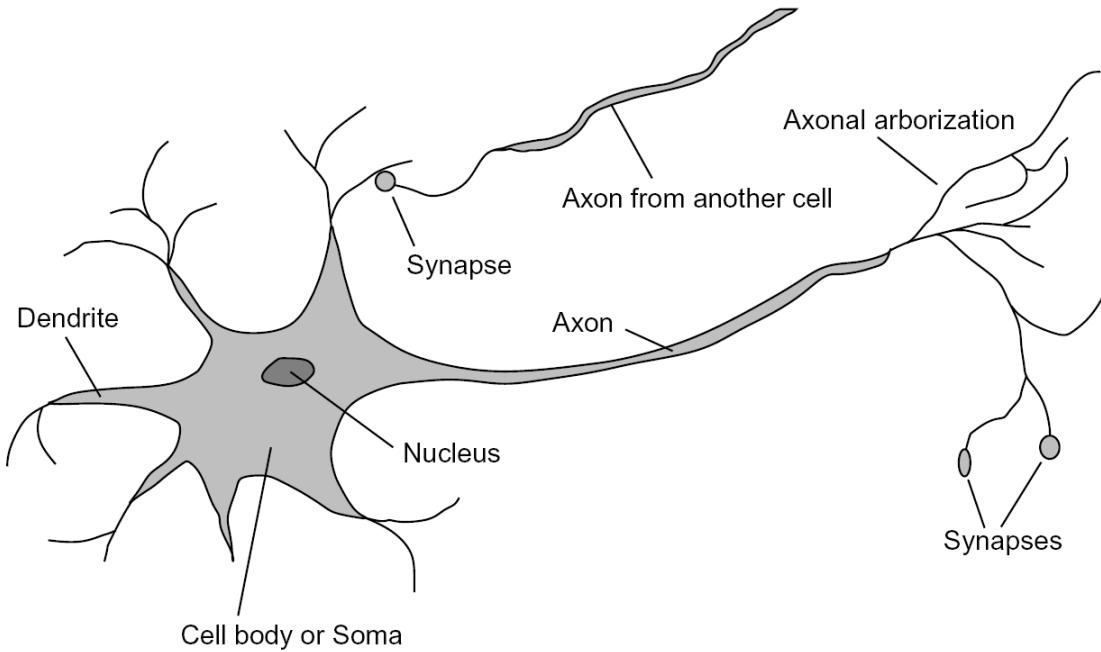
$\begin{Bmatrix} \text{PIXEL-7,12} & : 1 \\ \text{PIXEL-7,13} & : 0 \\ \dots \\ \text{NUM_LOOPS} & : 1 \\ \dots \end{Bmatrix}$



“2”

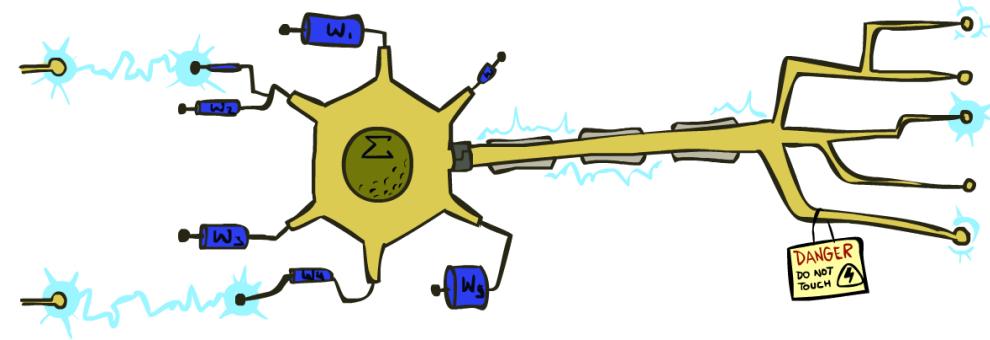
Némi (egyszerűsített) biológia

- inspiráció: emberi neuronok



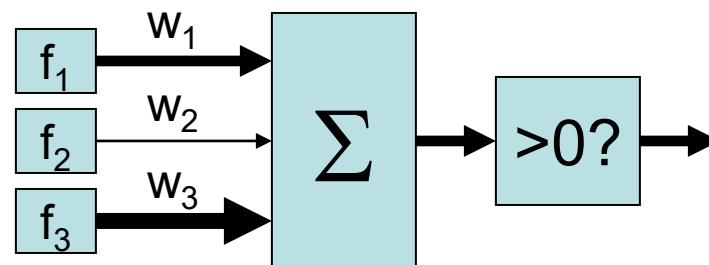
Lineáris osztályozók

- A bemenetek **változó** (jellemző, feature) értékek
- minden változónak van egy **súlya**
- Az összegzett eredmény (lineáris kombináció) az **aktiváció**



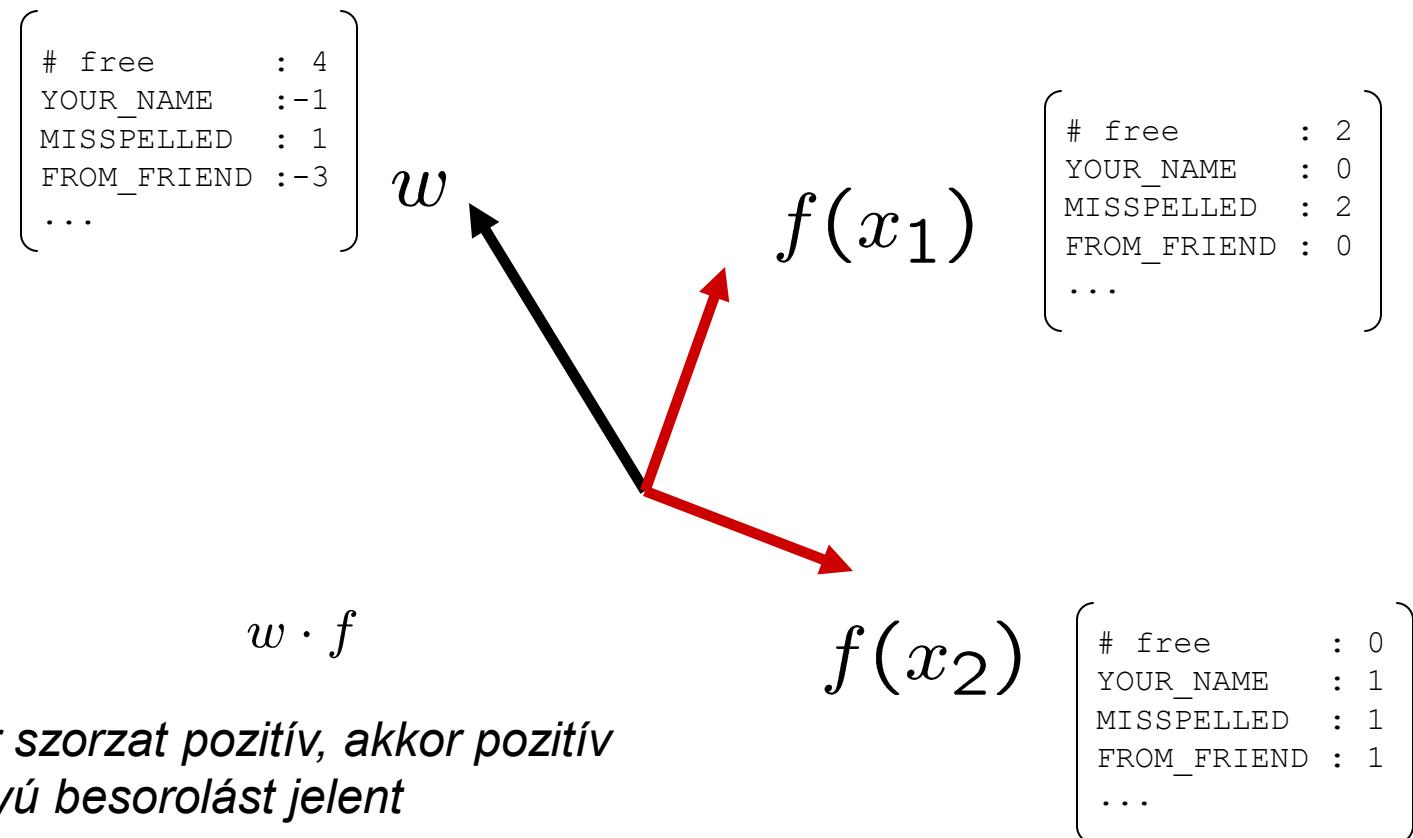
$$\text{activation}_w(x) = \sum_i w_i \cdot f_i(x) = w \cdot f(x)$$

- Kimenet az aktiváció szerint:
 - Pozitív, output: +1
 - Negatív, output: -1



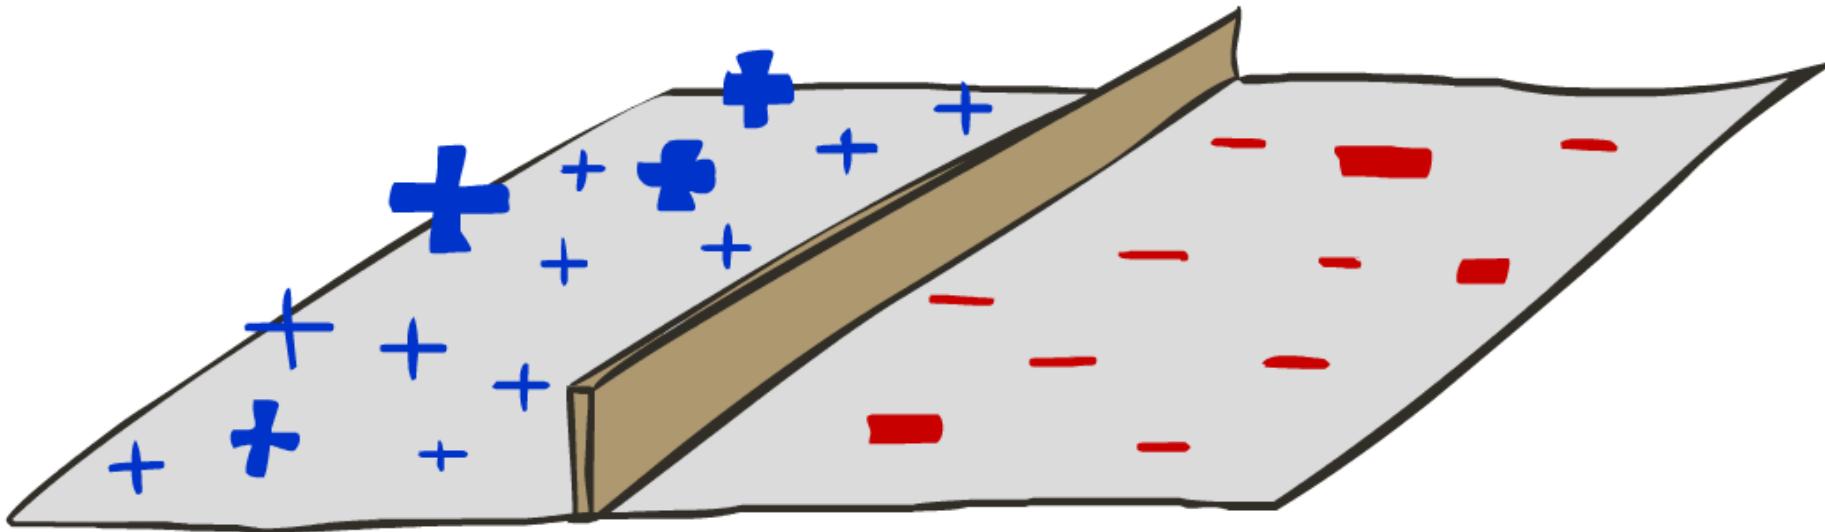
Súlyok

- Bináris eset: hasonlítsuk össze a jellemzőket egy súlyvektorral
- Tanulás: súlyvektor meghatározása példákból



Skalár szorzat pozitív, akkor pozitív osztályú besorolást jelent

Döntési szabályok

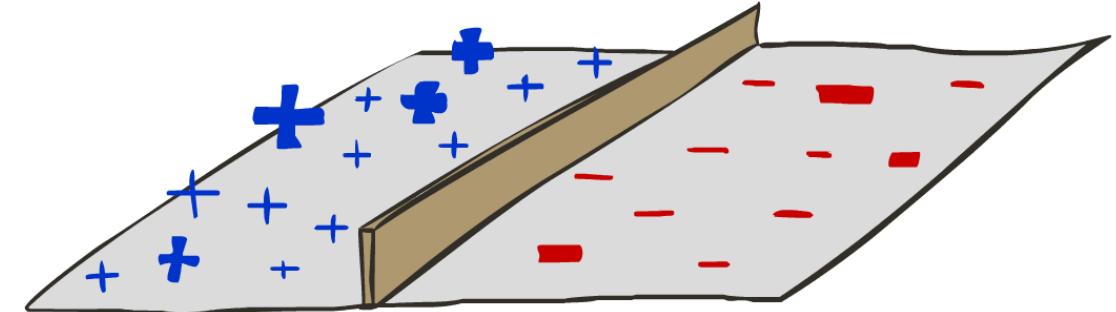
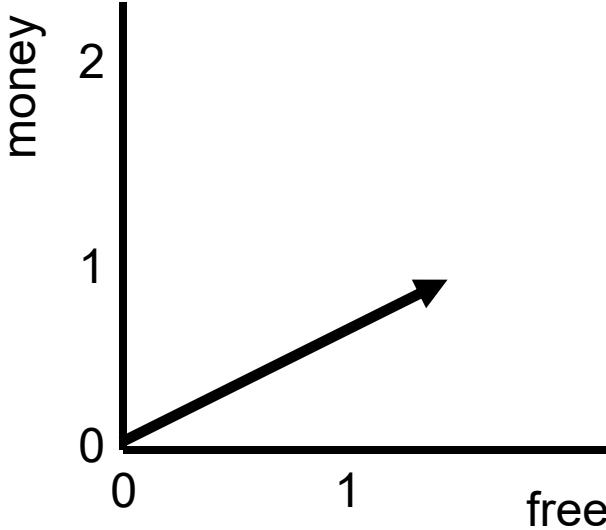


Bináris döntési szabály

- A jellemzővektorok terében
 - A minták a pontok
 - Bármely súlyvektor egy hipersík
 - Az egyik oldal megfelel $Y=+1$ -nek
 - A másik megfelel $Y=-1$ -nek

w

BIAS	:	-3
free	:	4
money	:	2
...		

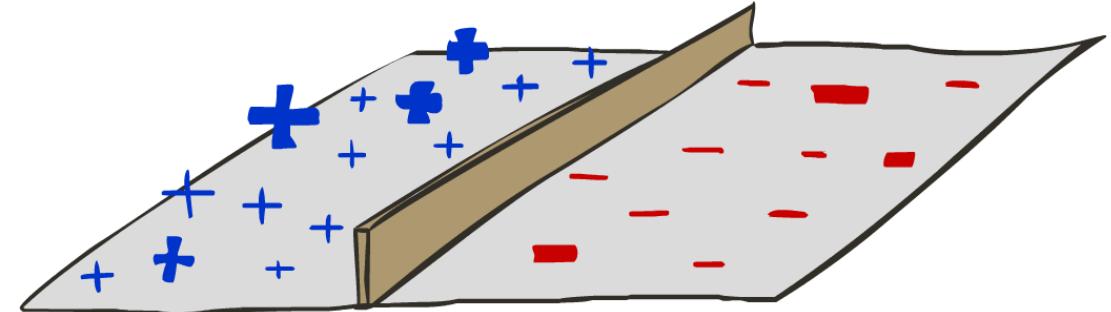
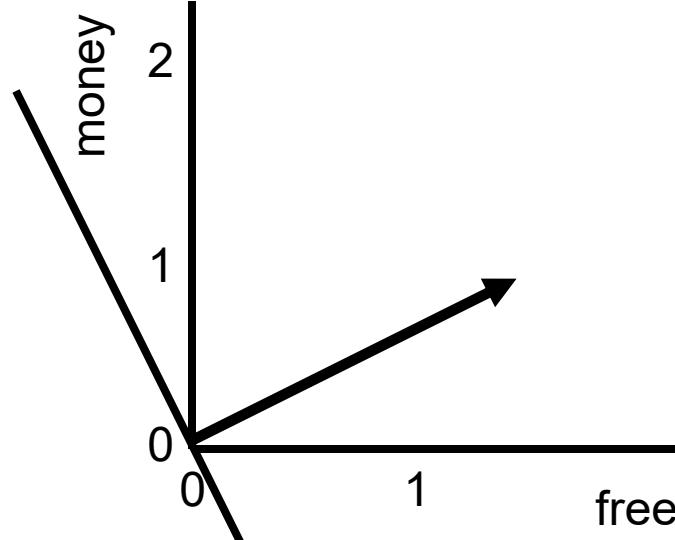


Bináris döntési szabály

- A jellemzővektorok terében
 - A minták a pontok
 - Bármely súlyvektor egy hipersík
 - Az egyik oldal megfelel $Y=+1$ -nek
 - A másik megfelel $Y=-1$ -nek

w

BIAS : -3
free : 4
money : 2
...

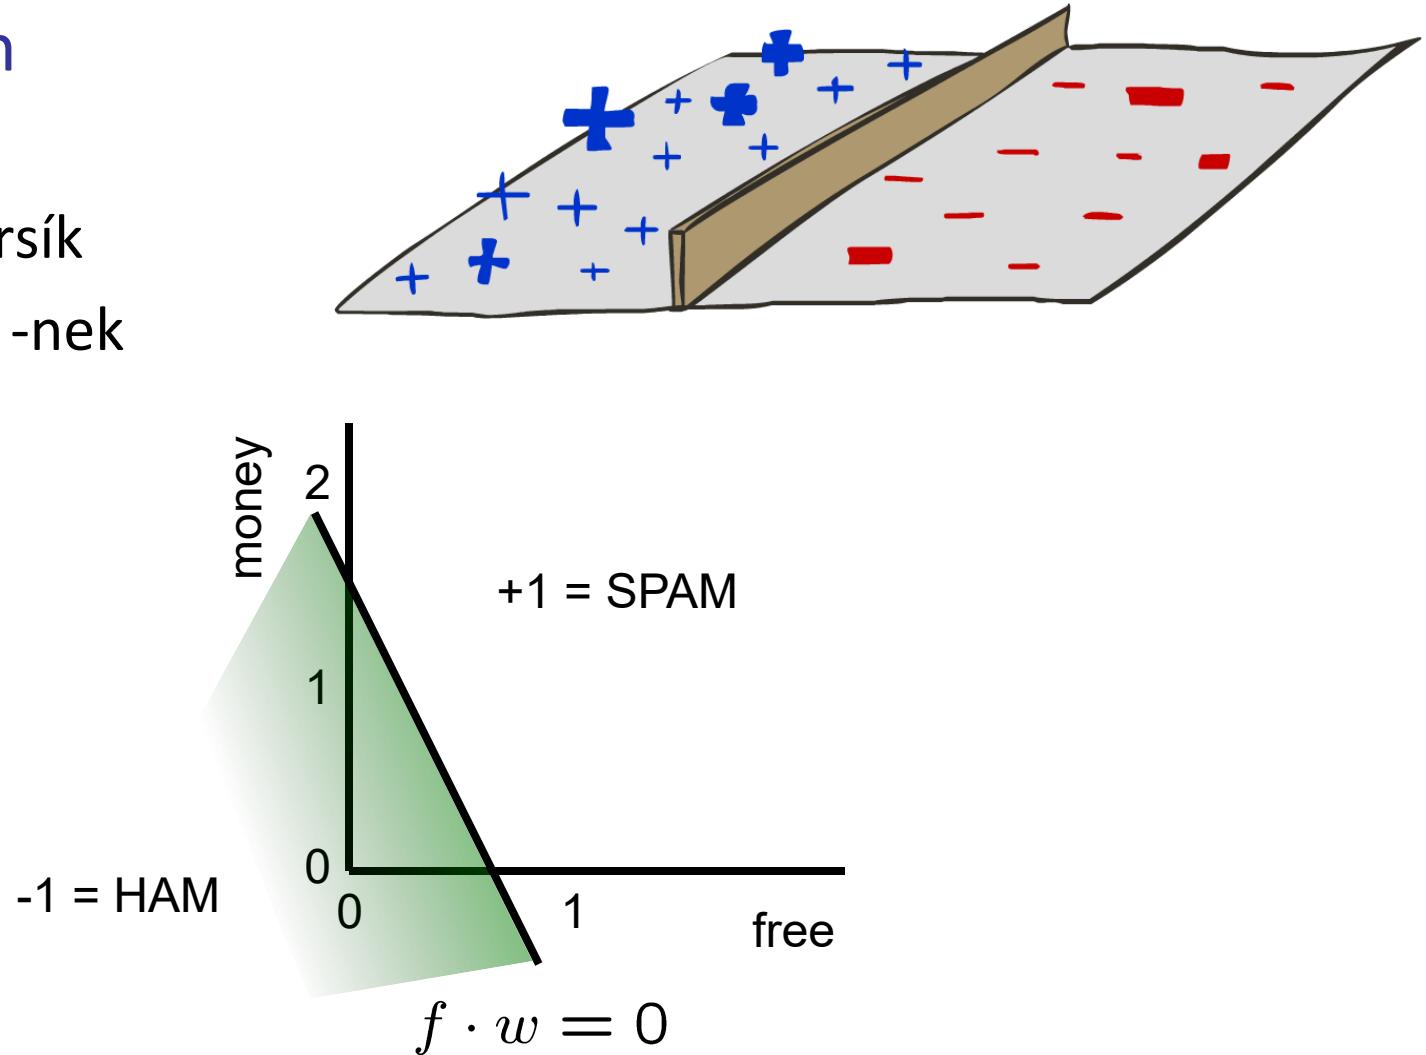


Bináris döntési szabály

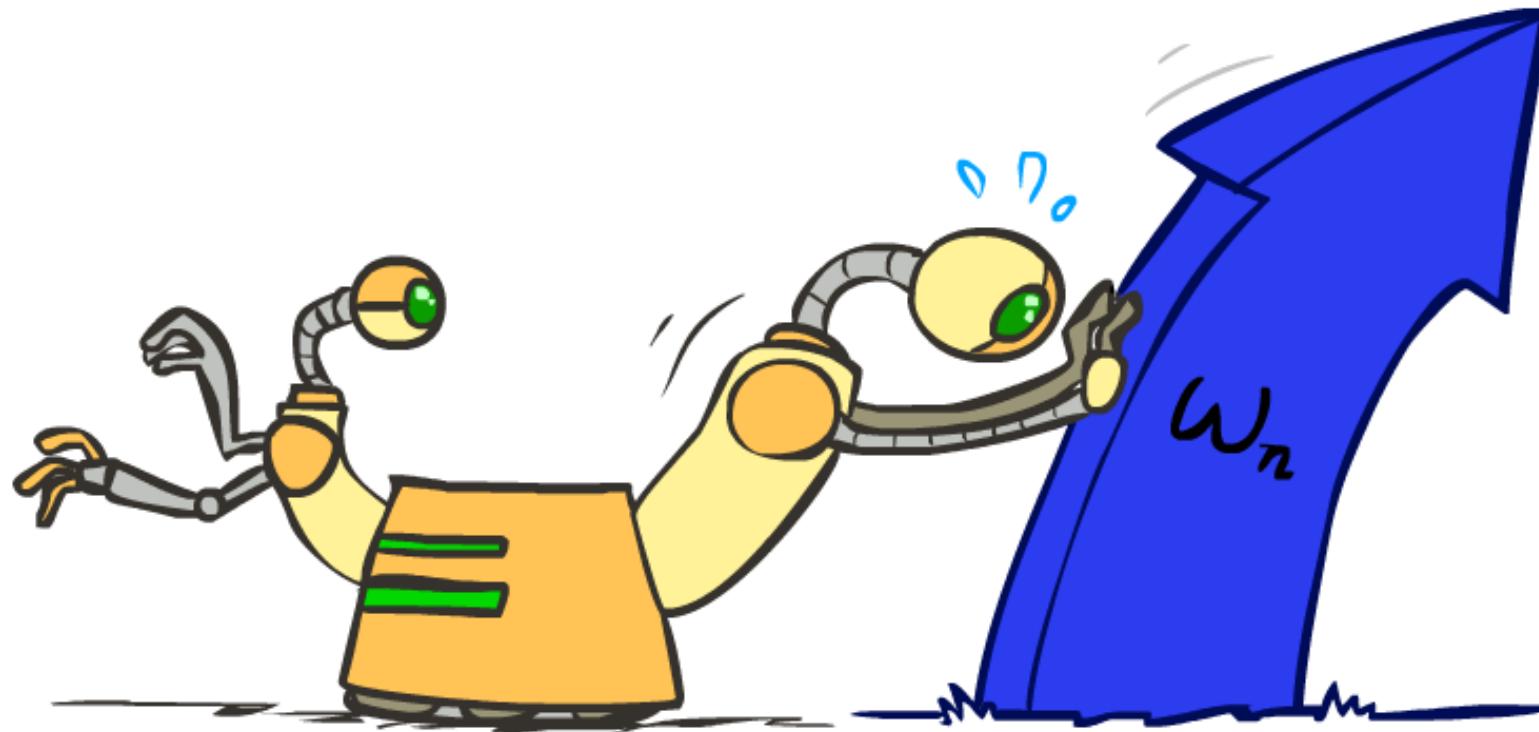
- A jellemzővektorok terében
 - A minták a pontok
 - Bármely súlyvektor egy hipersík
 - Az egyik oldal megfelel $Y=+1$ -nek
 - A másik megfelel $Y=-1$ -nek

w

BIAS : -3
free : 4
money : 2
...

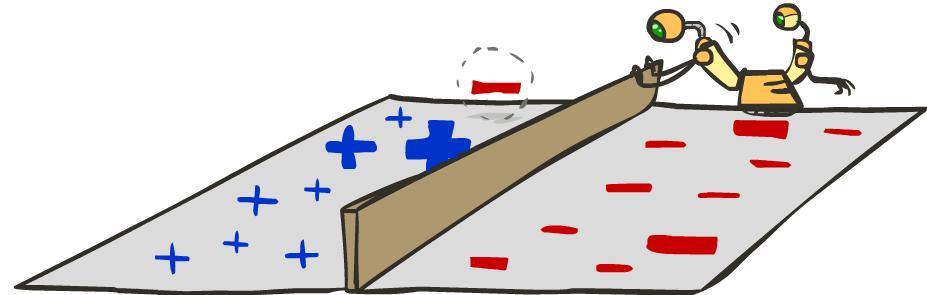
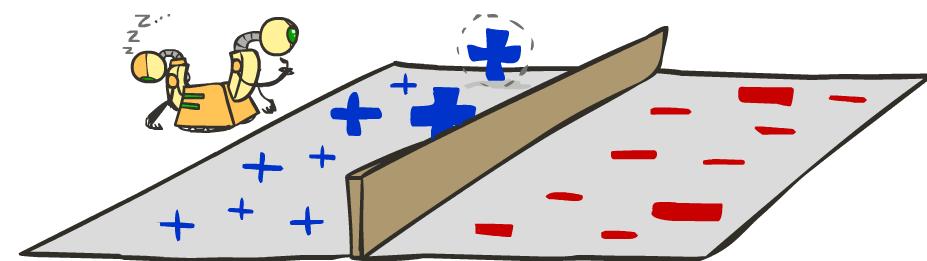
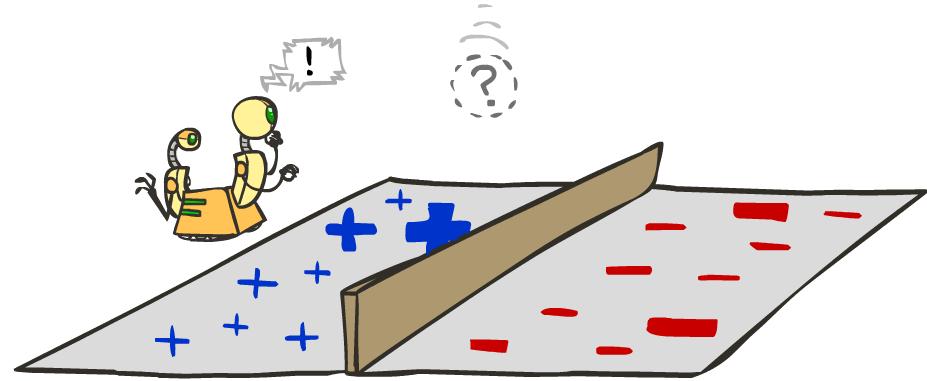


Súly frissítések



Tanulás: Bináris Perceptron

- Kezdetben: Súlyok = 0
- minden tanítási mintához:
 - Osztályozás az aktuális súlyok alapján
 - Ha helyes (azaz $y=y^*$), nincs változás!
 - Ha rossz: állítsa be a súlyvektort



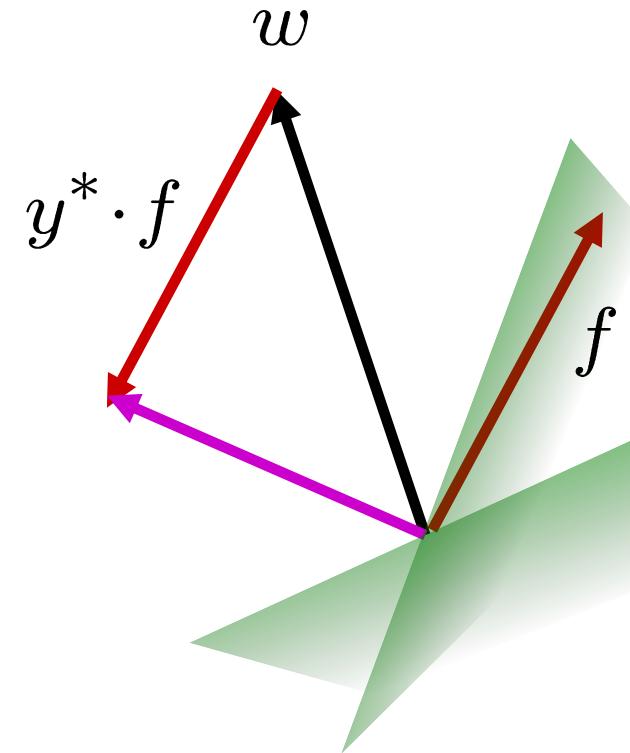
Tanulás: Bináris Perceptron

- Kezdetben: Súlyok = 0
- minden tanítási mintához:
 - Osztályozás az aktuális súlyok alapján

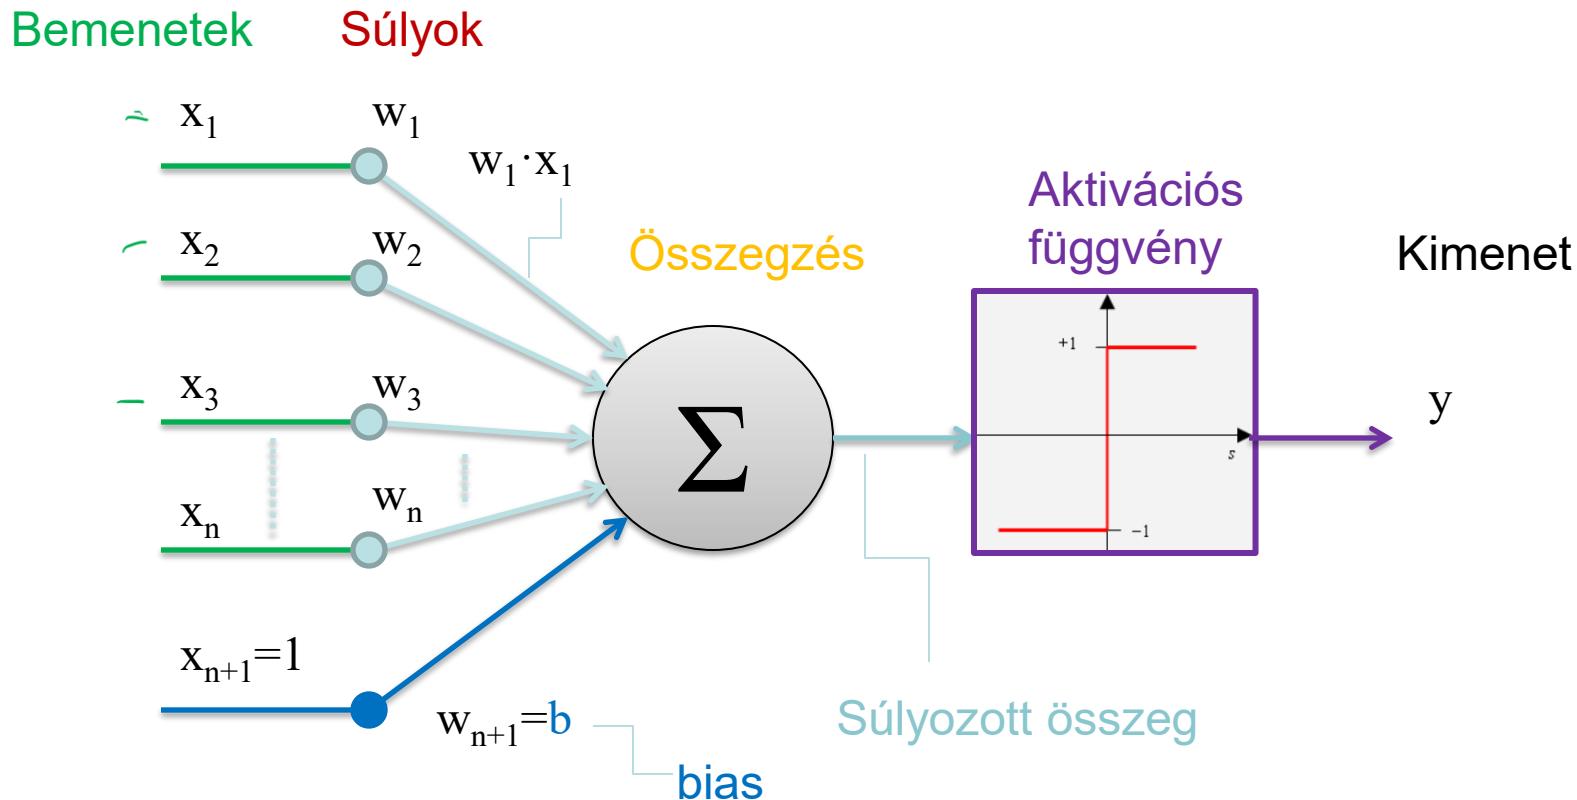
$$y = \begin{cases} +1 & \text{if } w \cdot f(x) \geq 0 \\ -1 & \text{if } w \cdot f(x) < 0 \end{cases}$$

- Ha helyes (azaz $y=y^*$), nincs változás!
- Ha helytelen: súlyvektor módosítása a jellemzővektor hozzáadásával vagy kivonásával. Kivonás, ha $y^* = -1$.

$$w = w + y^* \cdot f$$



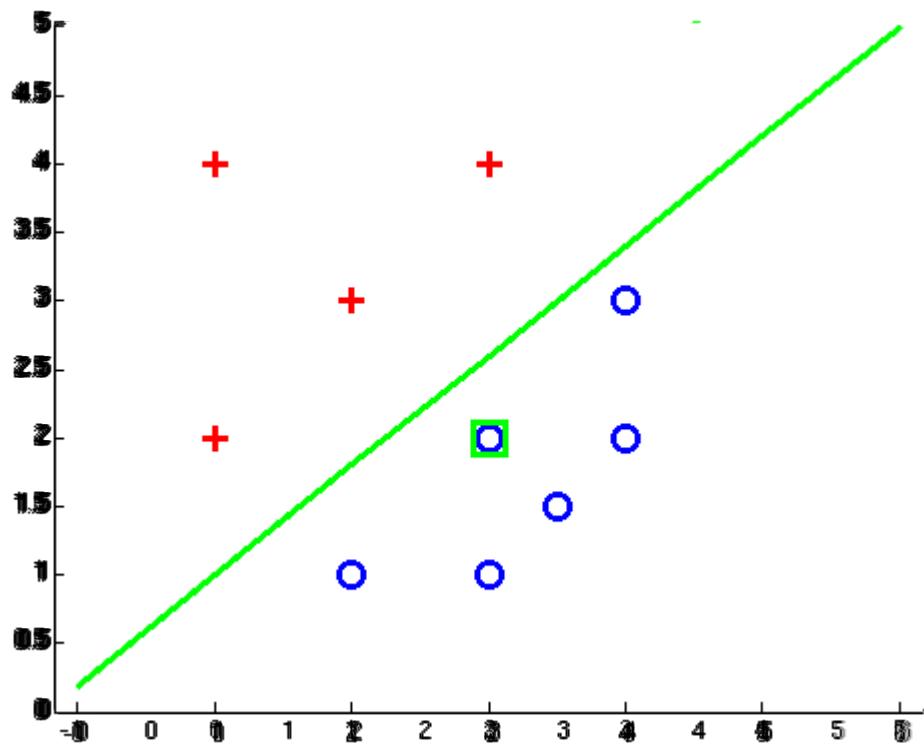
Perceptron



$$y = \text{sgn}\left(\sum_{i=1}^{n+1} w_i x_i\right) = \text{sgn}\left(\sum_{i=1}^n w_i x_i + w_{n+1}\right) = \text{sgn}(\mathbf{x}^T \mathbf{w} + b)$$

Példák: Perceptron

- Elkülöníthető eset



Többosztályos döntési szabály

- Ha több osztályunk van:
 - minden osztály súlyvektora:

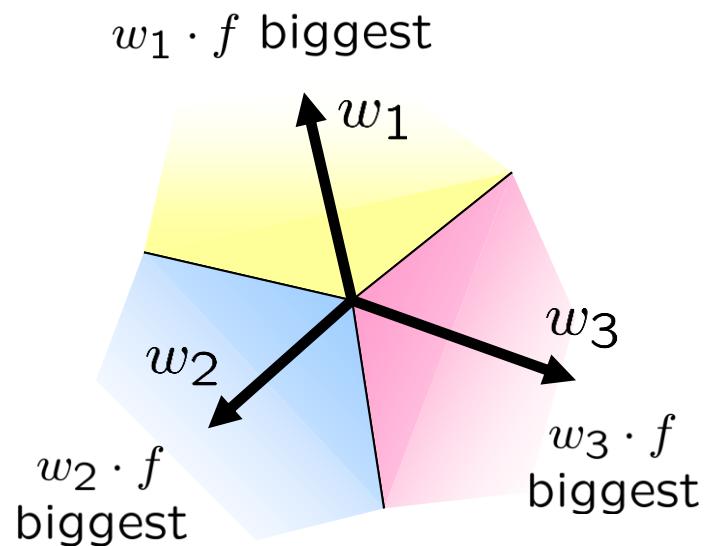
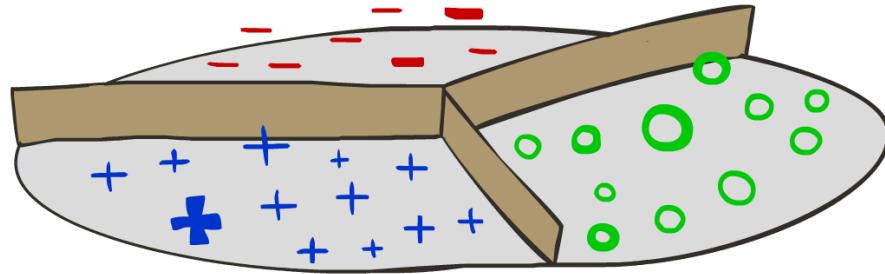
$$w_y$$

- az y osztály (aktivációja):

$$w_y \cdot f(x)$$

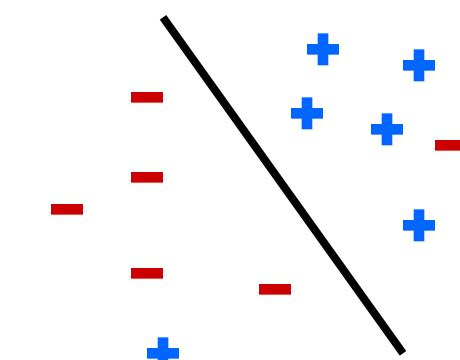
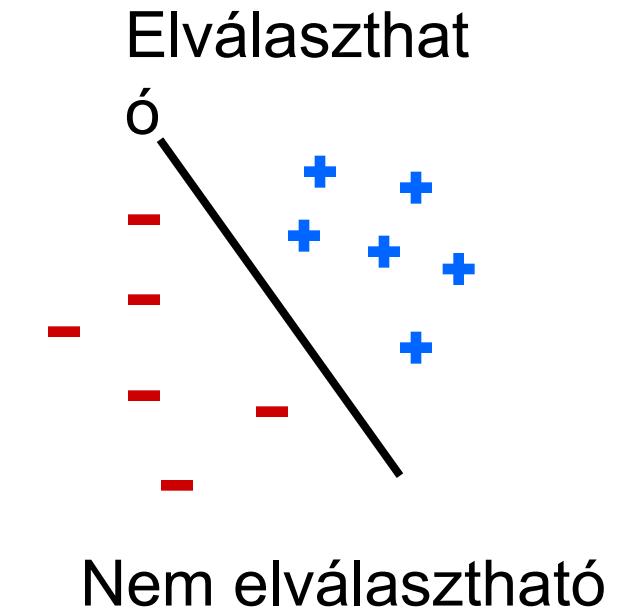
- Azaz előrejelzés nyer, amelyiknek legmagasabb az aktivációja

$$y = \arg \max_y w_y \cdot f(x)$$



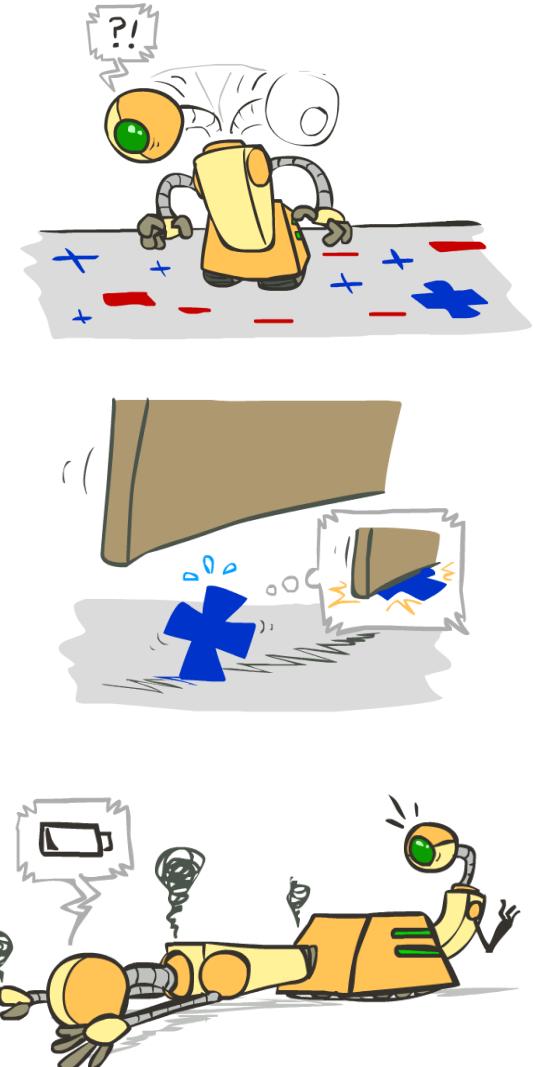
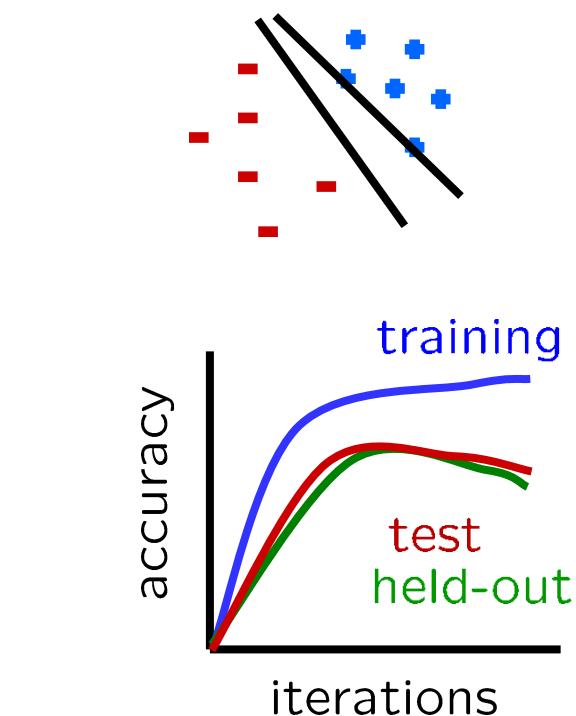
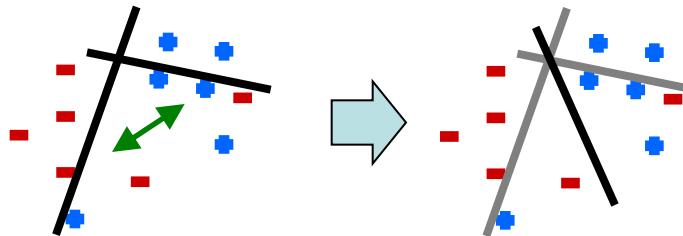
A perceptronok tulajdonságai

- **Elválaszthatóság:** igaz, ha egyes paraméterek alapján a modell tökéletesen szeparálja a mintákat
- **Konvergencia:** ha a tanító minta elválasztható, a perceptron végül konvergál (bináris esetben)

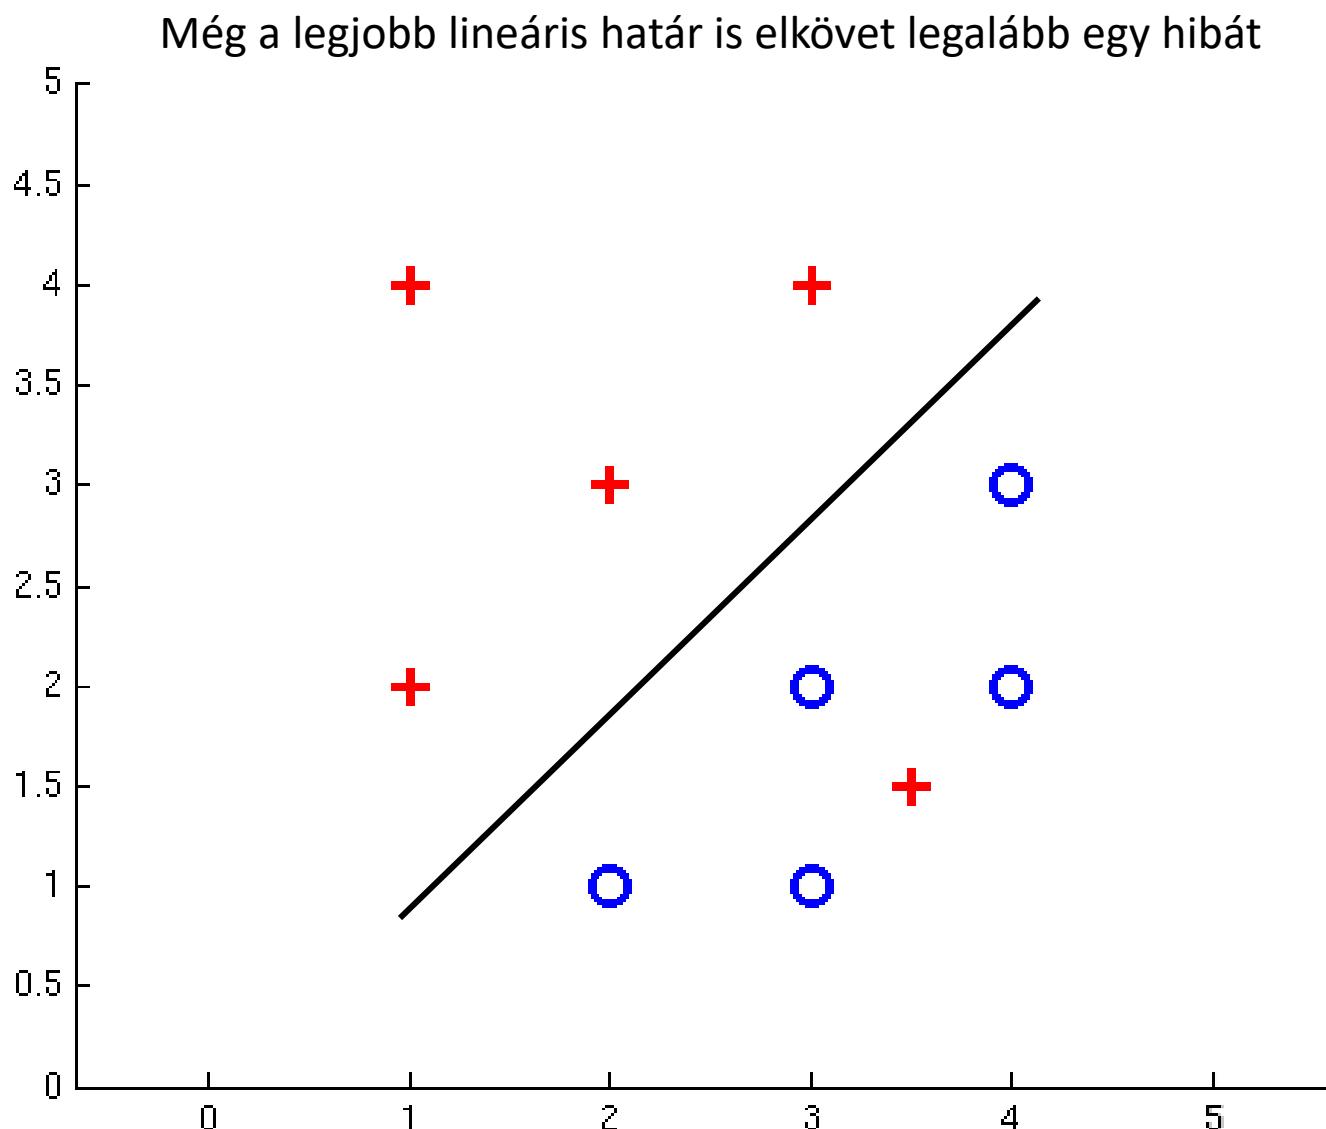


Problémák a Perceptronnal

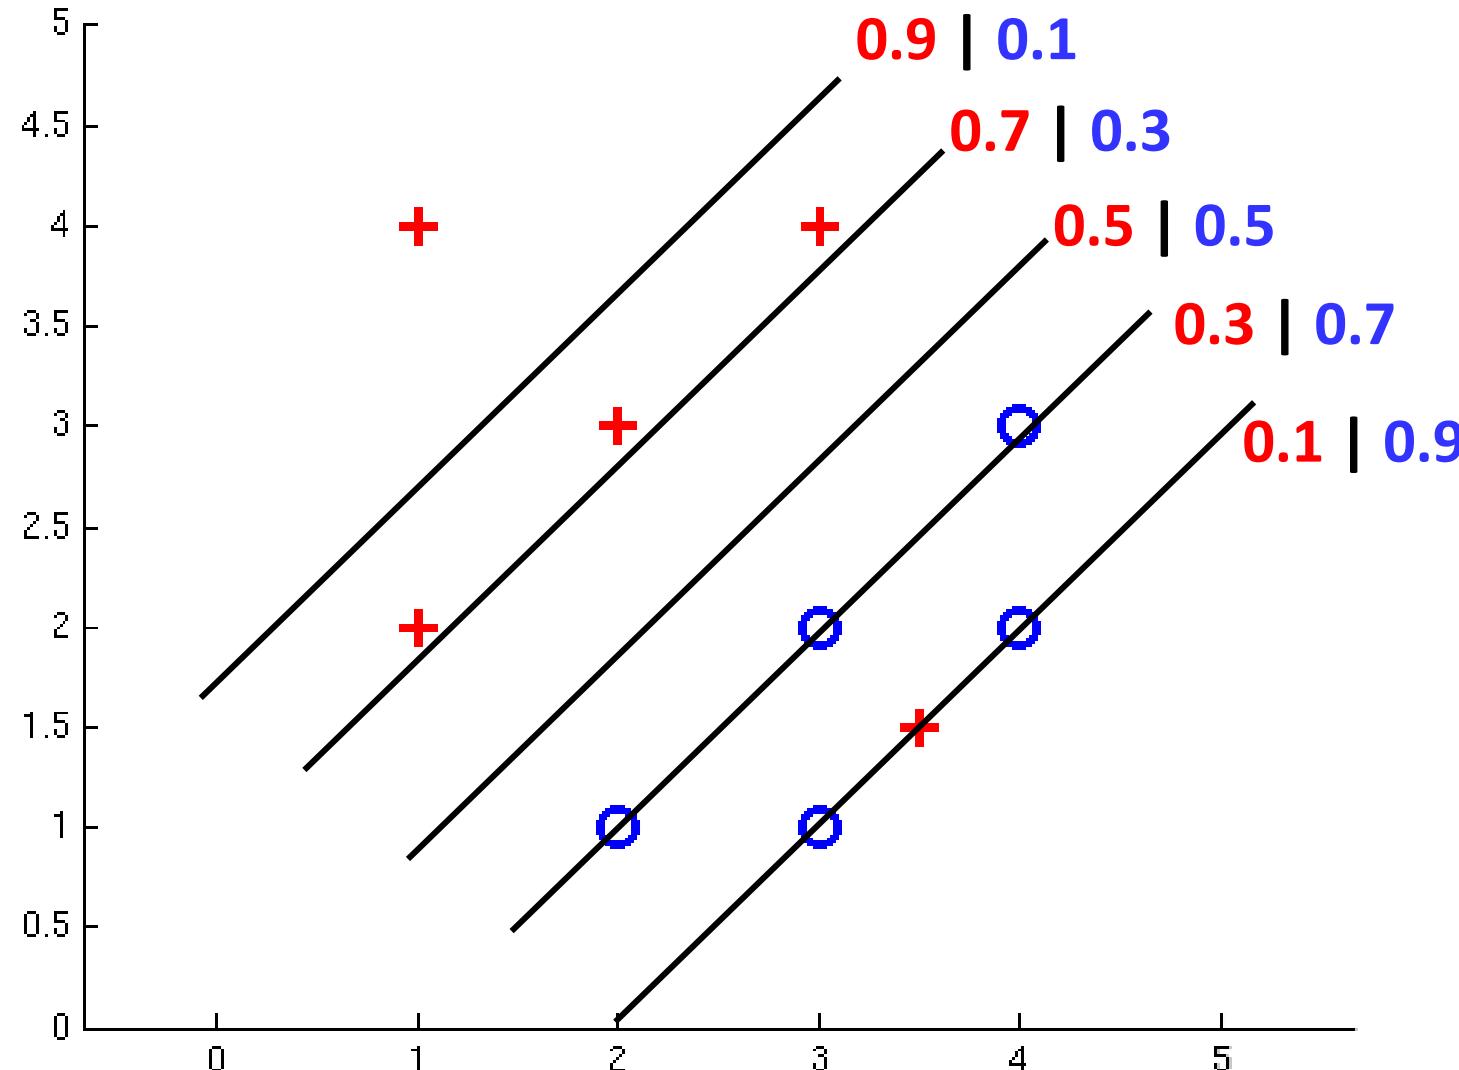
- Zaj: ha az adatok nem különíthetők el, a súlyok „kidőlhetnek”
- Középszerű általánosítás: "alig" elválasztó megoldást talál
- Túltanulás: a teszt / validációs adathalmazon a modell pontossága általában emelkedik, majd csökken
- A túltanulás egyfajta túlilleszkedés



Nem elválasztható eset: determinisztikus döntés



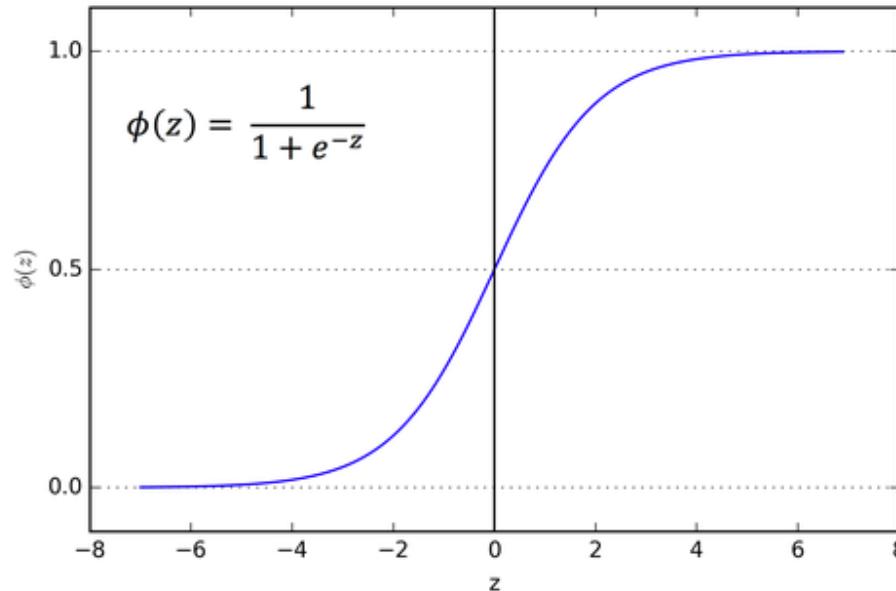
Nem szétválasztható eset: valószínűségi döntés



Hogyan lehet valószínűségi döntéseket hozni?

- Aktiváció: $z = w \cdot f(x)$
- Ha $z = w \cdot f(x)$ Pozitív \rightarrow a valószínűség 1-re közelítsen
- Ha $z = w \cdot f(x)$ Negatív \rightarrow a valószínűség 0-ra közelítsen
- Sigmoid függvény

$$\phi(z) = \frac{1}{1 + e^{-z}}$$



Legjobb w?

- Maximum likelihood becslés:

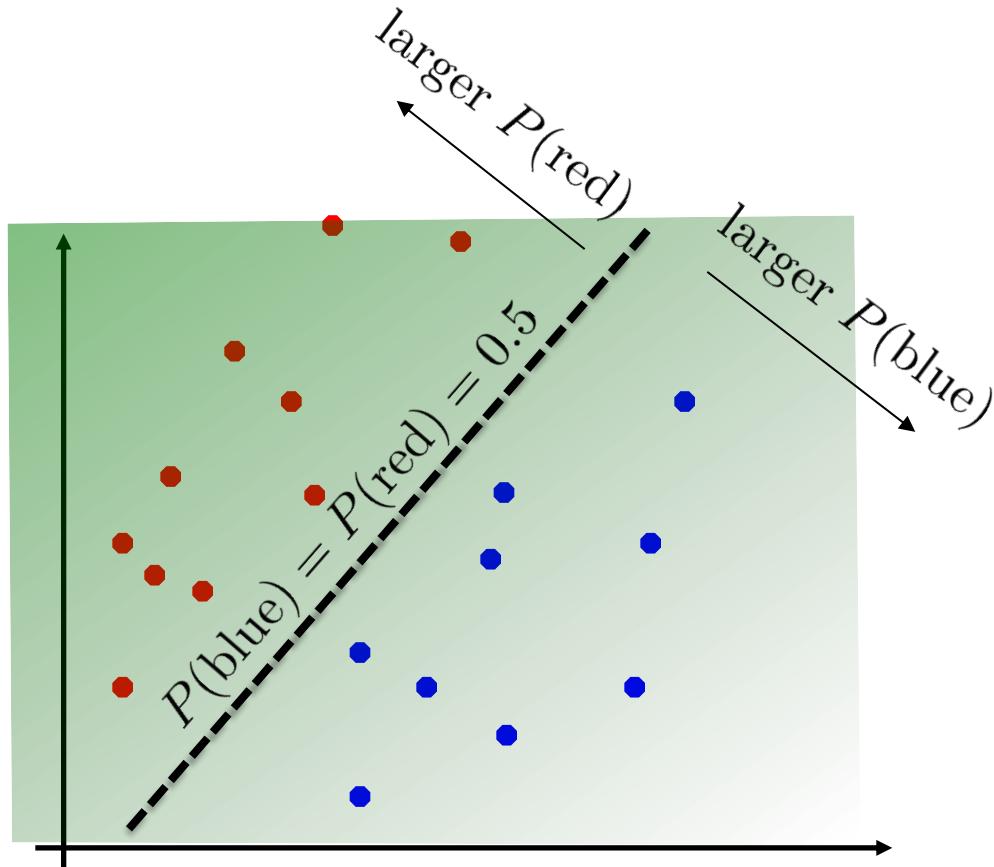
$$\max_w \text{ll}(w) = \max_w \sum_i \log P(y^{(i)} | x^{(i)}; w)$$

$$P(y^{(i)} = +1 | x^{(i)}; w) = \frac{1}{1 + e^{-w \cdot f(x^{(i)})}}$$

$$P(y^{(i)} = -1 | x^{(i)}; w) = 1 - \frac{1}{1 + e^{-w \cdot f(x^{(i)})}}$$

= Logisztikus regresszió

Valószínűségi perceptron



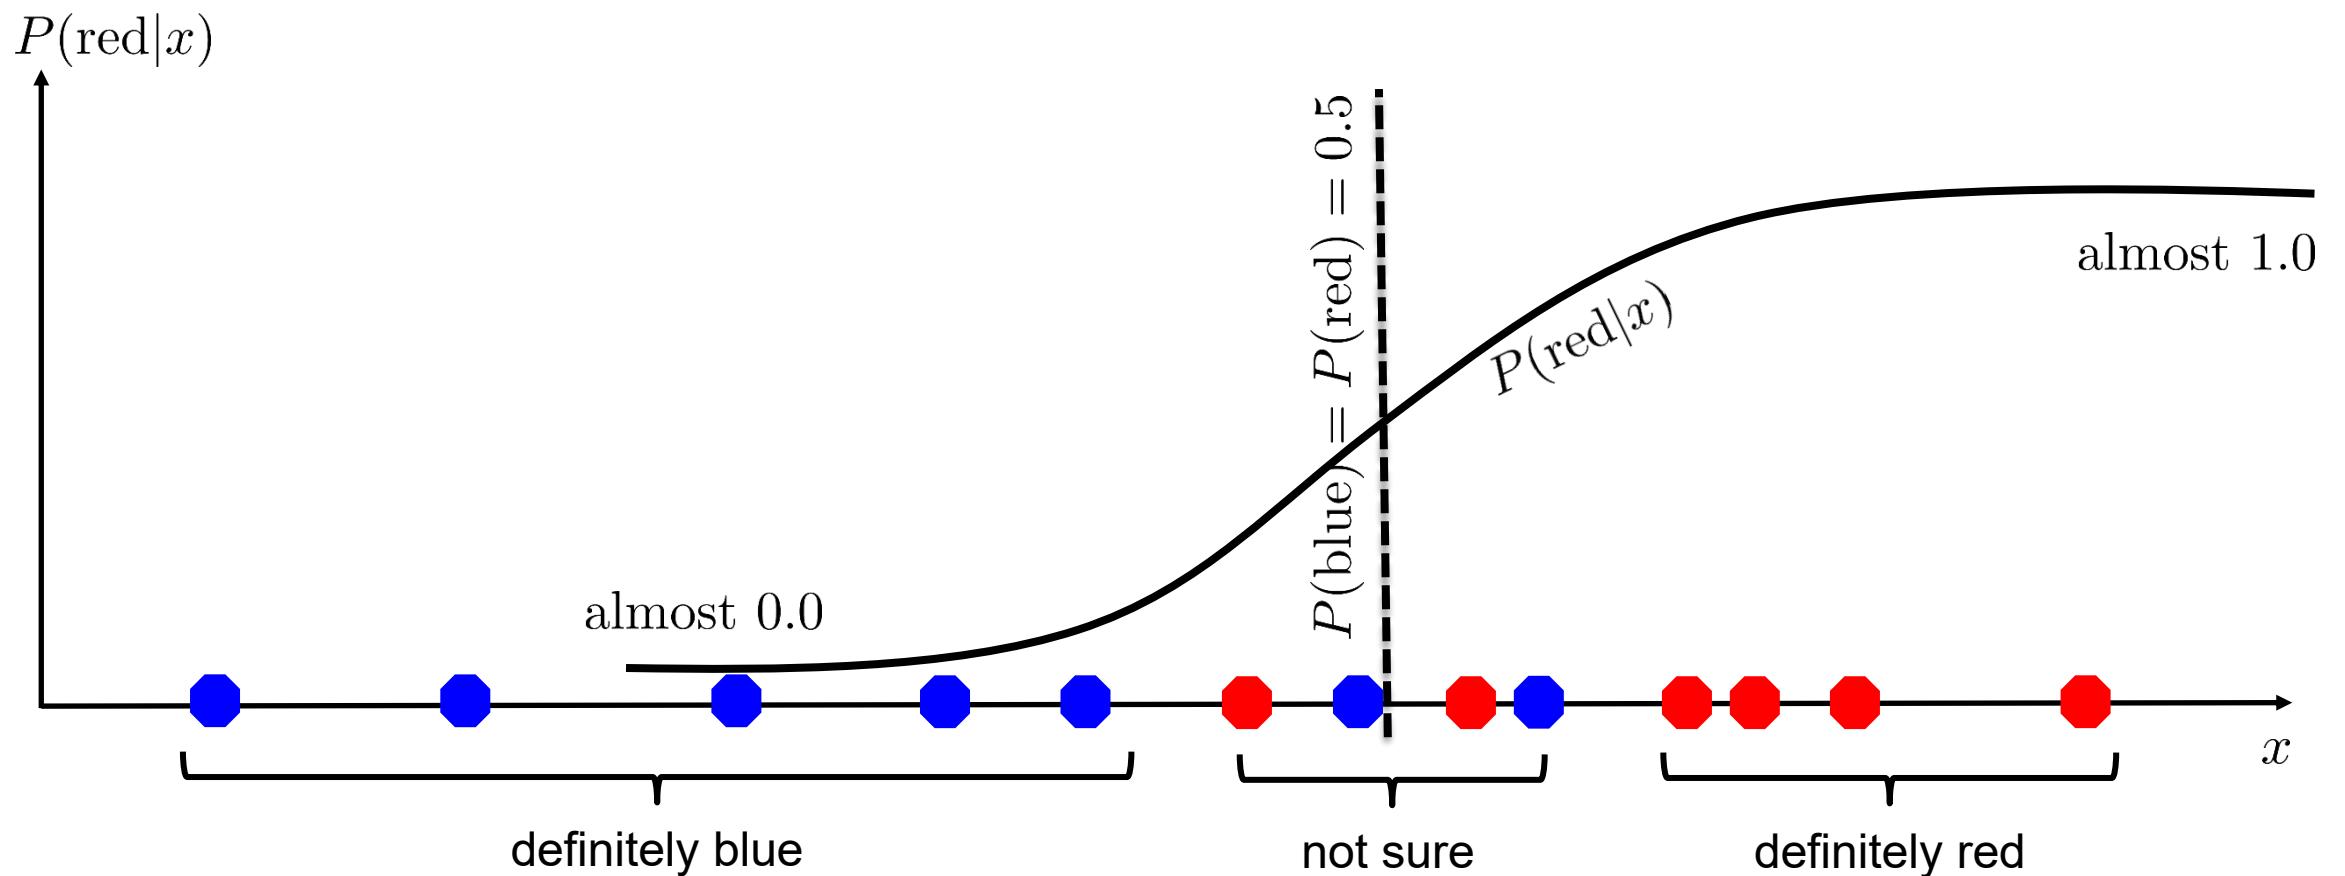
As $w_y \cdot x$ gets bigger, $P(y|x)$ gets bigger

1D Példa

$$P(\text{red}|x) = \frac{e^{w_{\text{red}} \cdot x}}{e^{w_{\text{red}} \cdot x} + e^{w_{\text{blue}} \cdot x}}$$

probability increases exponentially
as we move away from boundary

normalizer



Soft Max

$$P(\text{red}|x) = \frac{e^{w_{\text{red}} \cdot x}}{e^{w_{\text{red}} \cdot x} + e^{w_{\text{blue}} \cdot x}}$$

