Mesterséges intelligencia előadássorozat

Az előadás diái az AIMA könyvre épülve (http://aima.cs.berkeley.edu) készültek a University of California, Berkeley mesterséges intelligencia kurzusának anyagainak felhasználásával (http://ai.berkeley.edu).

These slides are based on the AIMA book (http://aima.cs.berkeley.edu) and were adapted from the AI course material of University of California, Berkeley (http://ai.berkeley.edu).

Racionalitás, hasznosságok, döntések

Előadó: Dr. Hullám Gábor

Hasznosságok

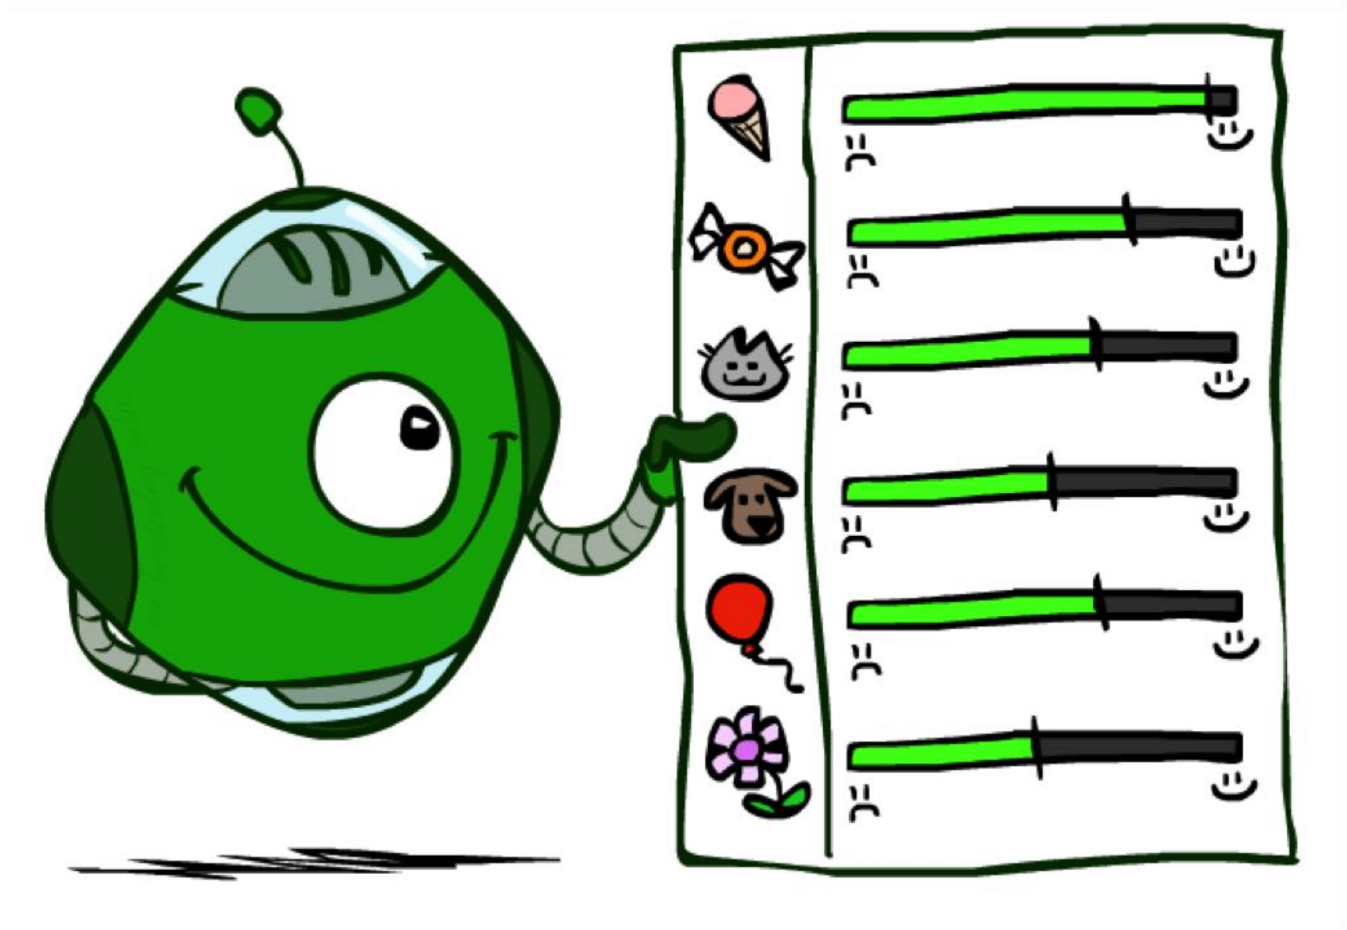

Maximális várható hasznosság

- Miért kellene átlagolnunk a hasznosságokat? Miért nem minimax?

- A maximális várható hasznosság elve:
- A racionális ágensnek azt a műveletet kell választania, amely maximalizálja várható hasznosságát, tekintettel tudására

- Kérdések:
  - Honnan származnak a hasznosságok?
  - Honnan tudjuk, hogy egyáltalán léteznek ilyen hasznosságok?
  - Honnan tudjuk, hogy az átlagolásnak egyáltalán van értelme?
  - Mi van, ha viselkedésünket (preferenciáinkat) nem lehet leírni hasznosságokkal?

Milyen hasznosságokat kellene használni?

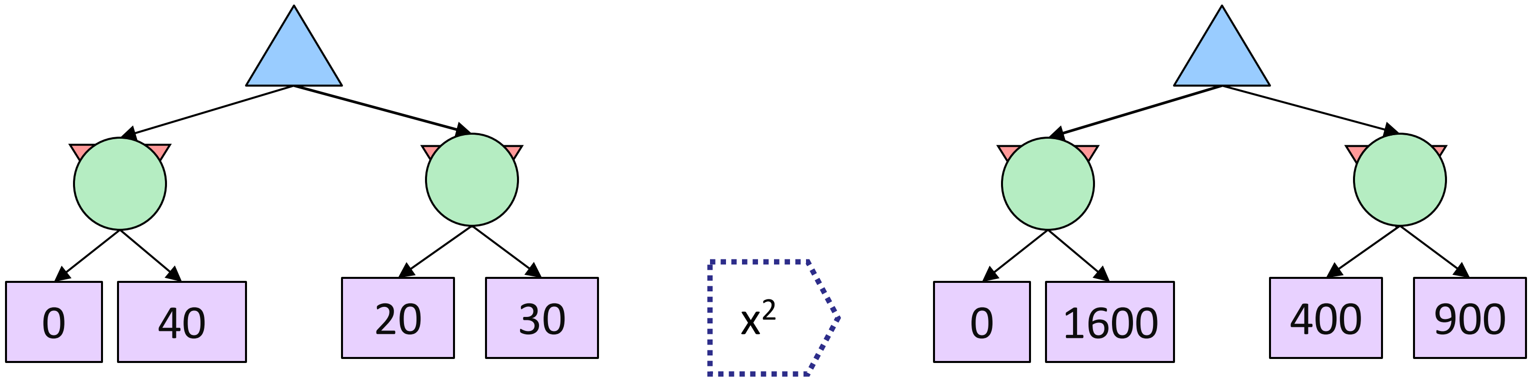

- A worst-case minimax következtetésnél, a hasznosságfüggvény skálája nem számít
  - Csak azt akarjuk, hogy a jobb állapotok magasabb értékelésekkel rendelkezzenek (legyen jó a sorrendezés)
  - Ezt úgy nevezzük, hogy érzéketlenség a monoton transzformációkkal szemben
- Az átlagos expectimax következtetéshez a nagyságrendnek értelmesnek kell lennie

Hasznosságok

- A hasznosságok olyan függvények, amelyek az kimeneteleket (a világ állapotait) képzik le a valós számokra terjednek, és leírják az ágens preferenciáit

- Honnan származnak a hasznosságok?
  - Egy játékban egyszerű lehet(+1/-1)
  - A hasznosságok összefoglalják az ágens céljait
  - Tétel: Bármely "racionális" preferencia összefoglalható hasznossági függvényként

- Rögzítünk hasznosságokat és hagyjuk, hogy viselkedések alakuljanak ki
- Miért nem hagyjuk, hogy az ágensek válasszanak hasznosságokat??
  - Miért nem írjuk elő a viselkedést??

Hasznosságok: bizonytalan kimenetelek

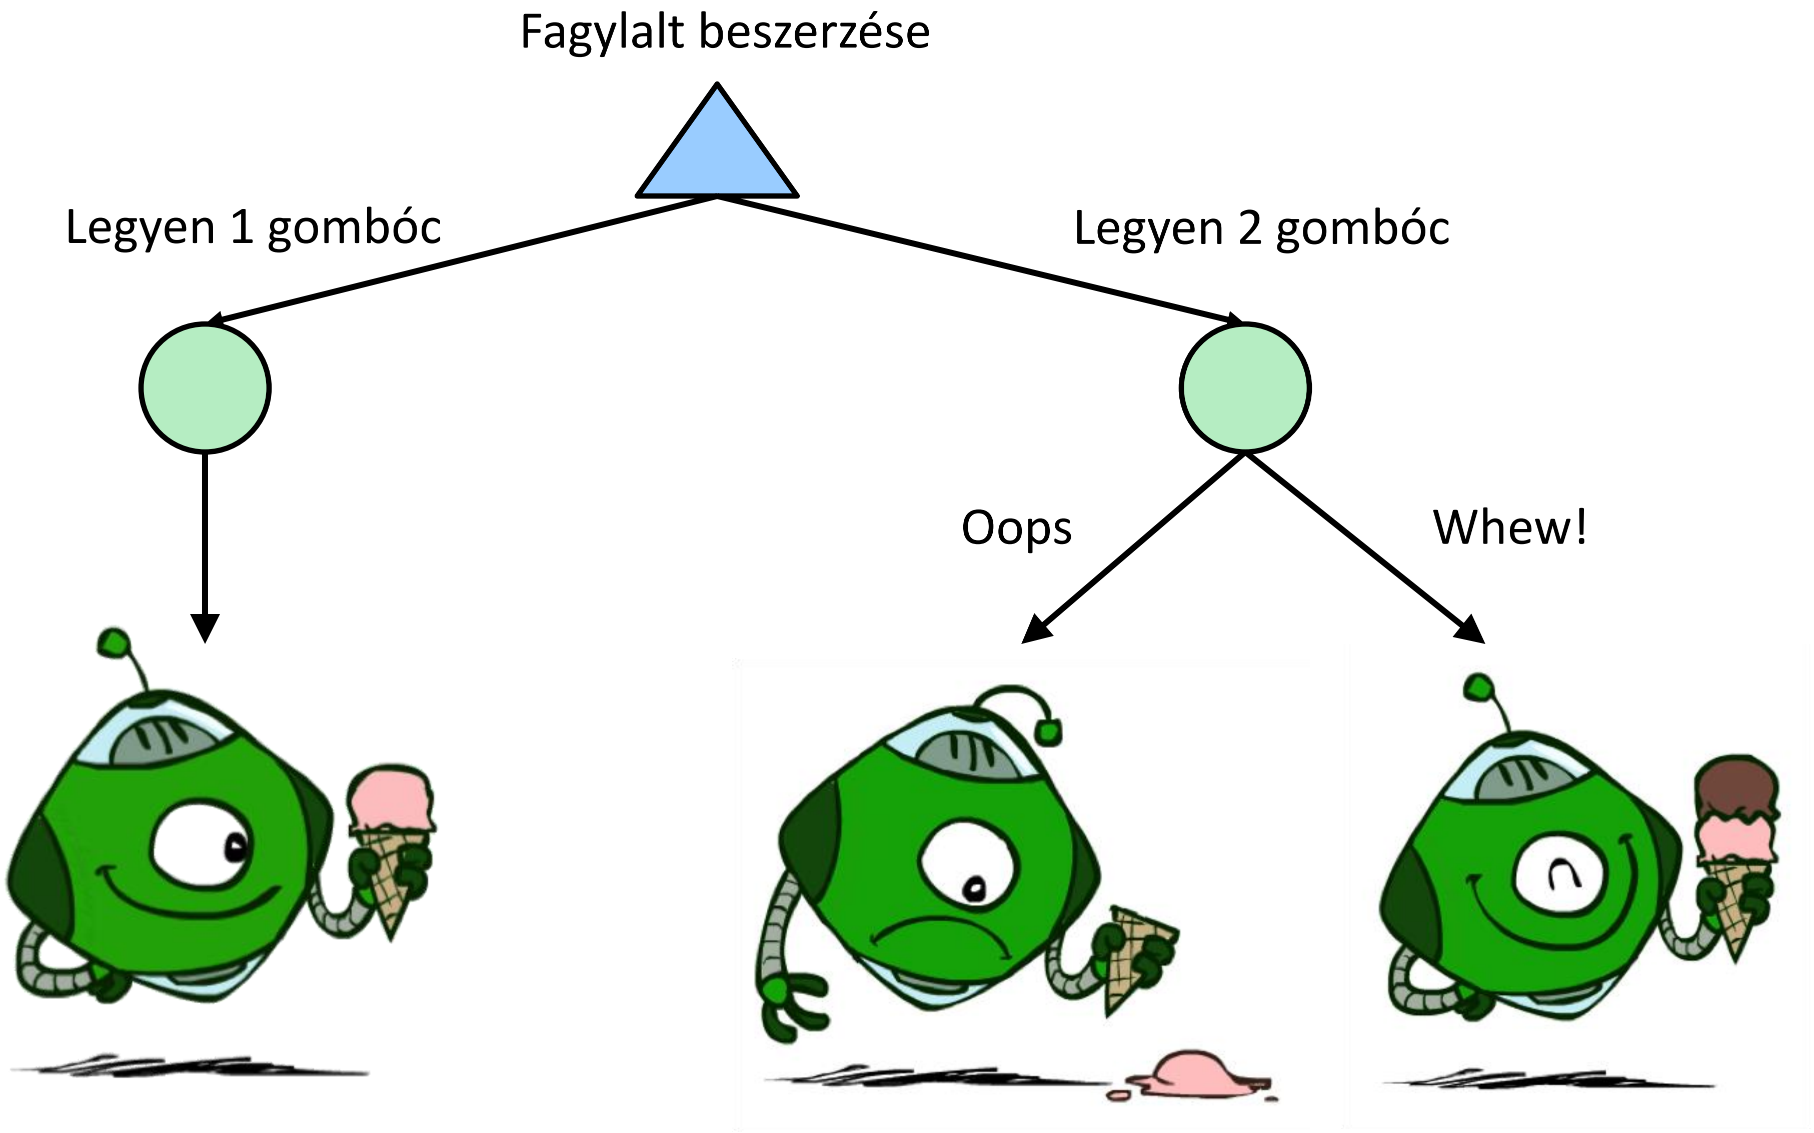

Preferenciák

- Az ágensnek preferenciákkal kell rendelkeznie a következők között:
  - Nyeremények: A, B.
  - Szerencsejáték: bizonytalan nyereményekkel járó helyzetek

$$L = [p, A;\ \ (1-p), B]$$

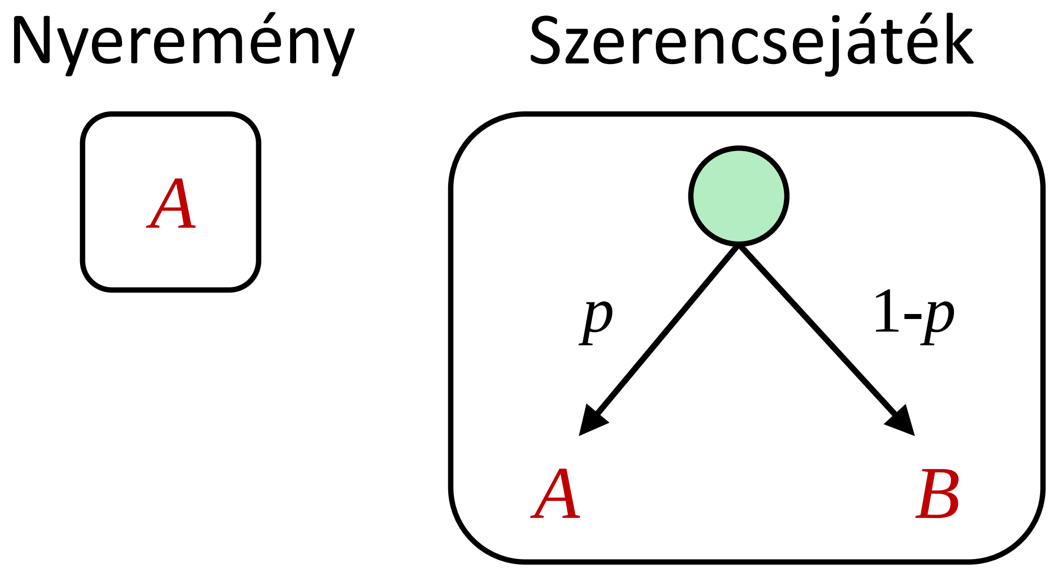

- Jelölés:
  - Preferencia: $A \succ B$
  - Közömbösség: $A \sim B$

Racionalitás

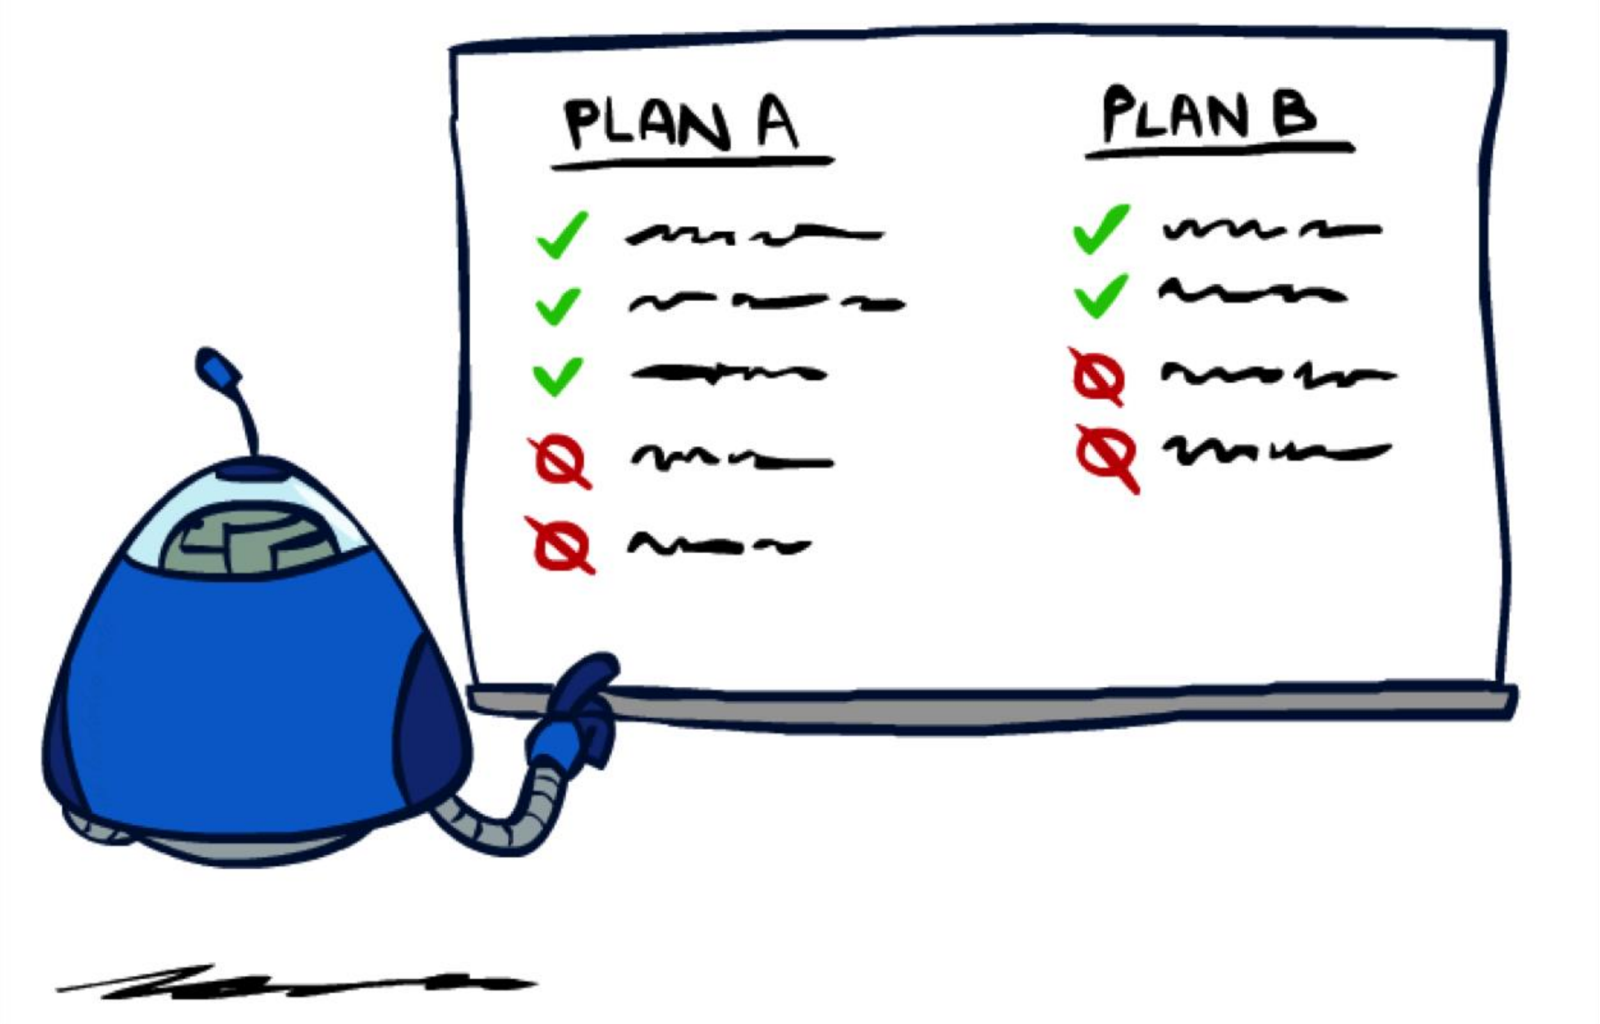

Racionális preferenciák

- Szeretnénk néhány korlátozást a preferenciákra, mielőtt racionálisnak neveznénk őket, például:

Tranzitivitás axióma:

- $A \succ B \land B \succ C \Rightarrow A \succ C.$

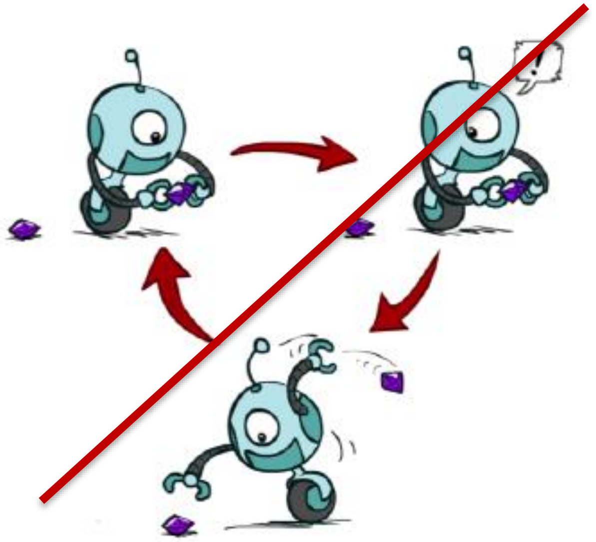

Racionális preferenciák

- Ellenpélda: egy intranzitív preferenciákkal rendelkező ágenst rá lehet bírni, hogy adja oda az összes pénzét:
  - Ha $B \succ C$, akkor egy C-vel rendelkező ügynök fizetne pl. 1 centet, hogy megszerezze B-t.
  - Ha $A \succ B$, akkor egy B-vel rendelkező ügynök fizetne pl. 1 centet, hogy megszerezze A-t.
  - Ha $C \succ A$, akkor egy A-val rendelkező ügynök fizetne pl. 1 centet, hogy megszerezze C-t.

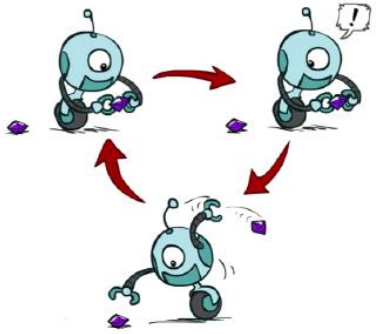

Racionalitás axiómái

Orderability

$$(A \succ B) \vee (B \succ A) \vee (A \sim B)$$

Transitivity

$$(A \succ B) \wedge (B \succ C) \Rightarrow (A \succ C)$$

Continuity

$$A \succ B \succ C \Rightarrow \exists p\ [p, A;\ 1-p, C] \sim B$$

Substitutability

$$A \sim B \Rightarrow [p, A;\ 1-p, C] \sim [p, B; 1-p, C]$$

Monotonicity

$$A \succ B \Rightarrow (p \geq q \Leftrightarrow [p, A;\ 1-p, B] \succeq [q, A;\ 1-q, B])$$

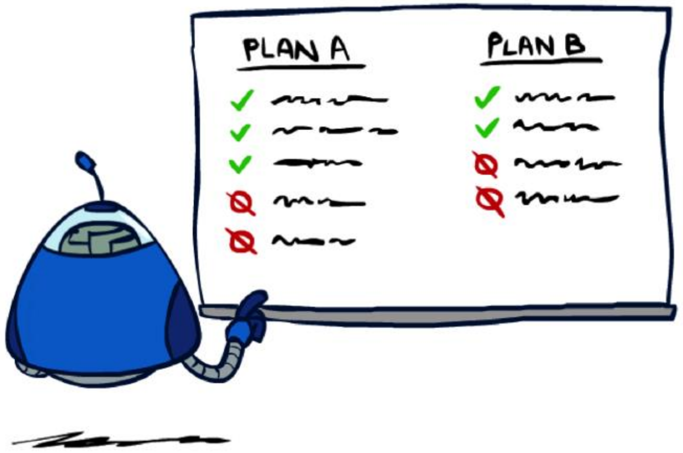

Racionalitás axiómái

Orderability

$$(A \succ B) \vee (B \succ A) \vee (A \sim B)$$

Transitivity

$$(A \succ B) \wedge (B \succ C) \Rightarrow (A \succ C)$$

Continuity

$$A \succ B \succ C \Rightarrow \exists p\ [p, A;\ 1-p, C] \sim B$$

Substitutability

$$A \sim B \Rightarrow [p, A;\ 1-p, C] \sim [p, B; 1-p, C]$$

Monotonicity

$$A \succ B \Rightarrow$$
$$(p \geq q \Leftrightarrow [p, A;\ 1-p, B] \succsim [q, A;\ 1-q, B])$$

Tétel: A racionális preferenciák olyan viselkedést eredményeznek, amely a várható hasznosság maximalizálásaként írható le.

MEU - elv

Tétel(ek) [Ramsey, 1931; Neumann & Morgenstern, 1944]

- Figyelembe véve azokat a preferenciákat, amelyek kielégítik ezeket a kényszereket (axiómákat), ott létezik egy valós értékű U függvény, amelyre igaz, hogy
  - $U(A) \geq U(B) \leftrightarrow A \gtrsim B$
  - U([p1,S1;p2,S2; $\ldots \mathrm{p}n, Sn]) = \sum_i p_i U(S_i)$
- Vagyis az U által hozzárendelt értékek megőrzik a preferenciáit, mind a nyereményeknek, mind a sorsolásoknak.

MEU - elv

Maximum expected utility (MEU) elv:

- Válassza ki mindig azt a műveletet, amely maximalizálja a várható hasznosságot

Megjegyzés: egy ágens lehet teljesen racionális (összhangban a MEU-val) anélkül, hogy valaha is hasznosságokat vagy valószínűségeket ábrázolna vagy manipulálna (pl. keresőtábla)

Emberi hasznosságfüggvények

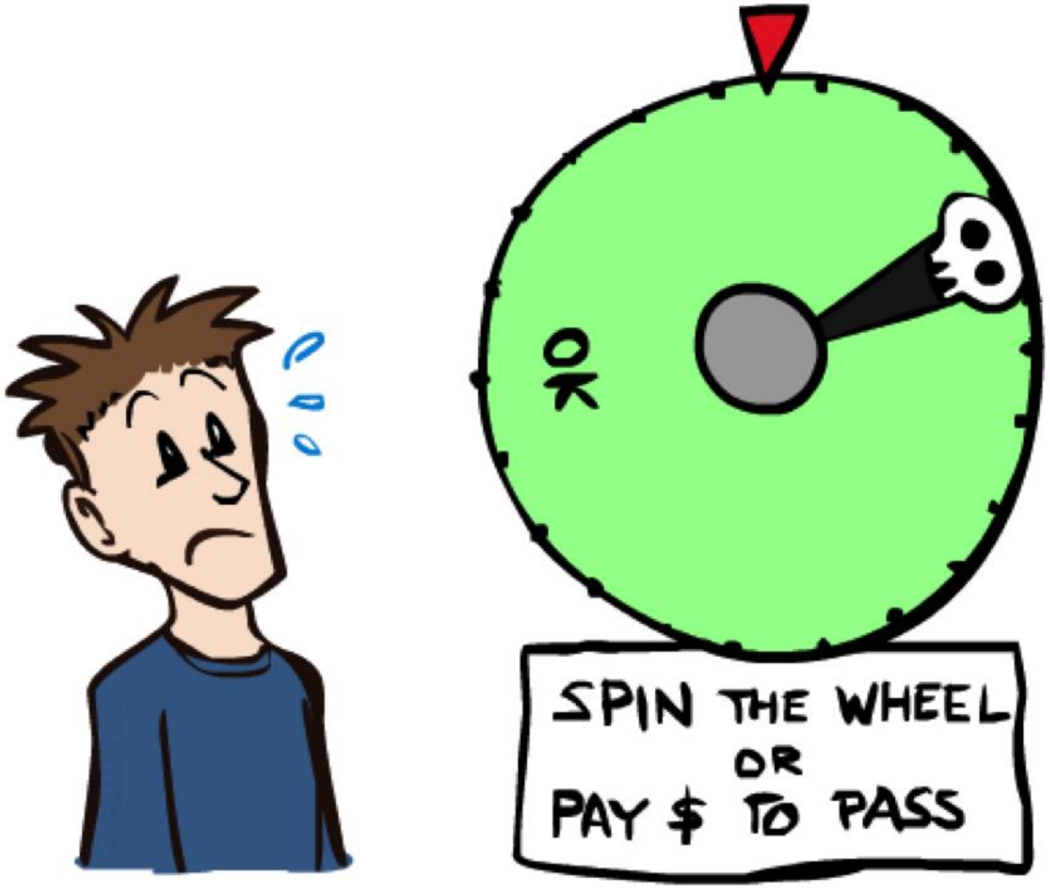

- Normalizált hasznosságok: u+ = 1.0; u- = 0.0.
- Mikromort: a halál egymilliomod esélye
- QALY-k: a minőség-igazított életévek, hasznosak orvosi döntéseknél, melyek jelentős kockázattal járnak
- Megjegyzés: a viselkedés invariáns pozitív lineáris transzformáció alatt
  - U0 (x) = k1U (x) + k2
- Ha csak determinisztikus nyeremények vannak (nincsenek szerencsejátékok), akkor csak a hasznosságok sorrendje meghatározható

Emberi hasznosságfüggvények

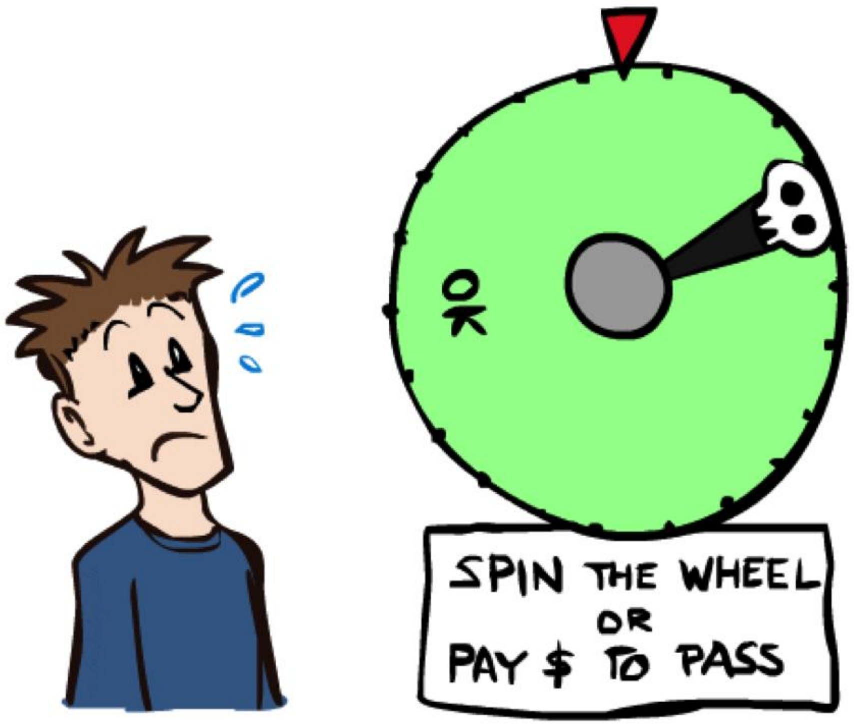

- Standard megközelítés a hasznosságok értékeléshez:
- Hasonlítsa össze az A nyereményt egy Lp szerencsejátékkal , ahol a
  - A lehetséges legjobb nyereményt p valószínűséggel kapjuk
  - A lehetséges legrosszabb nyereményt 1- p valószínűséggel kapjuk
- Állítsa a *p* szerencsejáték valószínűségét közömbösségig:
  A ~ Lp
  Az eredményül adódó p a [0,1] tartománybeli hasznossággal lesz egyenértékű

pay $30 ~

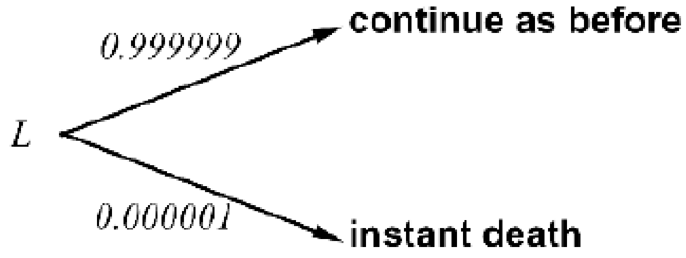

Emberi hasznosságfüggvények

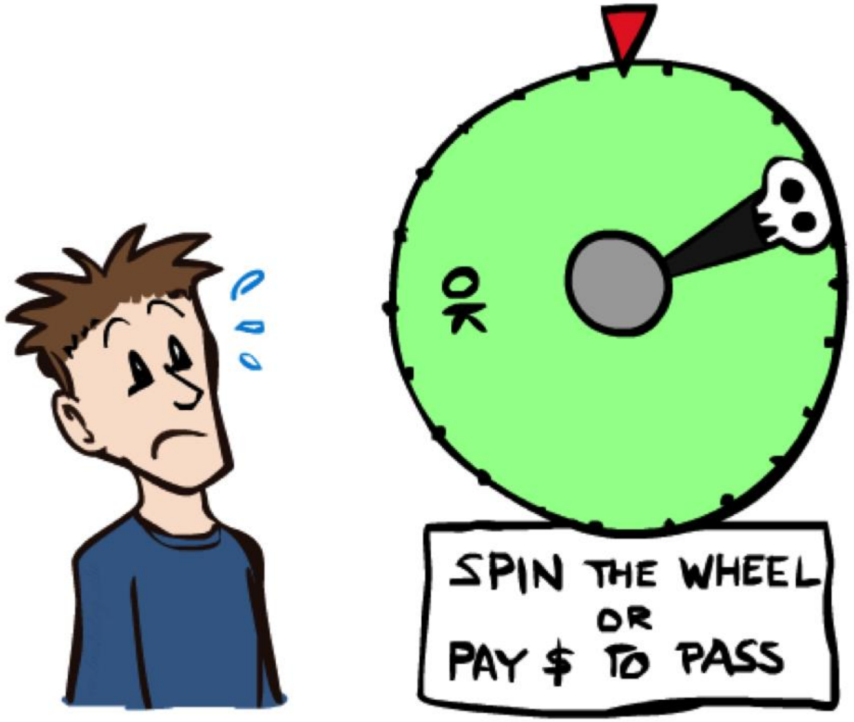

- A pénz nem viselkedik hasznosságfüggvényként, de a pénz birtoklása/adósság tekinthető hasznosságként

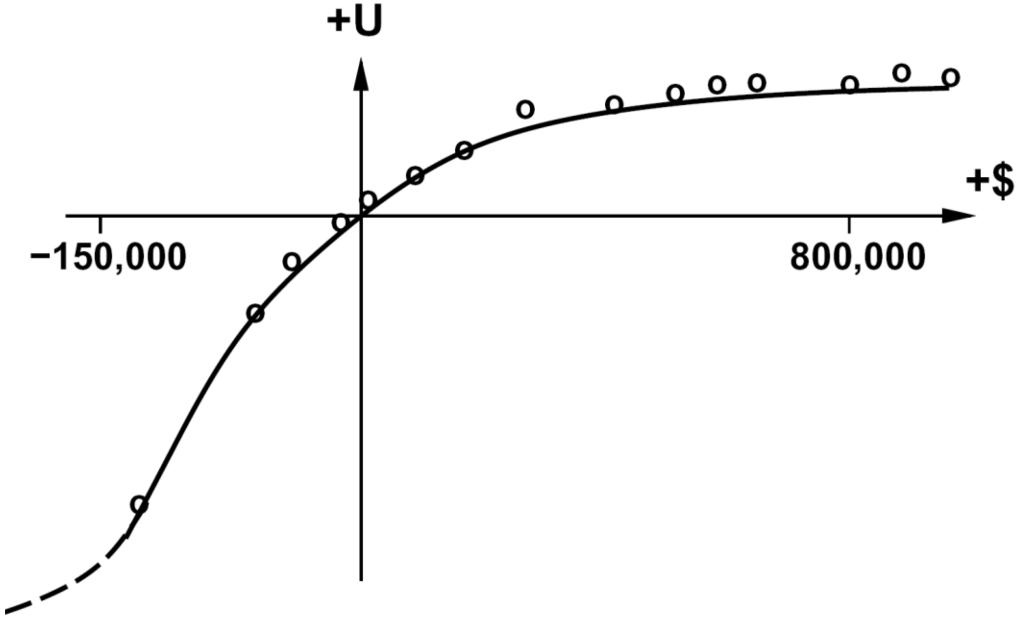

Emberi hasznosságfüggvények

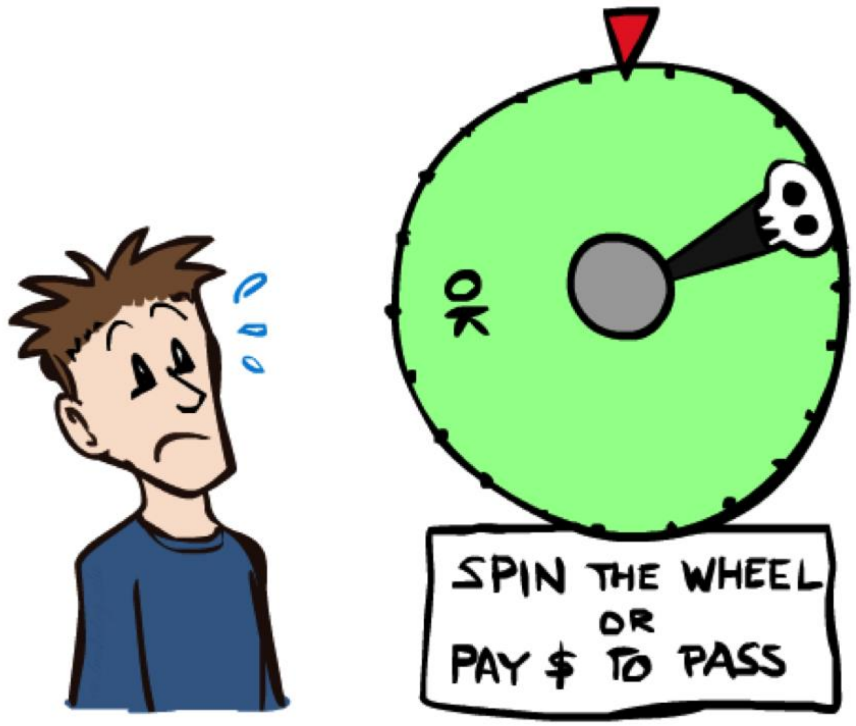

- Adott lottón L = [p, $ X; (1-p), $ Y]

Várható monetáris érték

- EMV (L): p X + (1-p) Y

- U (L) = p U ($ X) + (1-p) U ($ Y)

- Általában U (L) <U (EMV (L))
- Ebben az értelemben az emberek kockázatkerülők

- Adósság esetén az emberek kockázatvállalók

Emberi hasznosságfüggvények

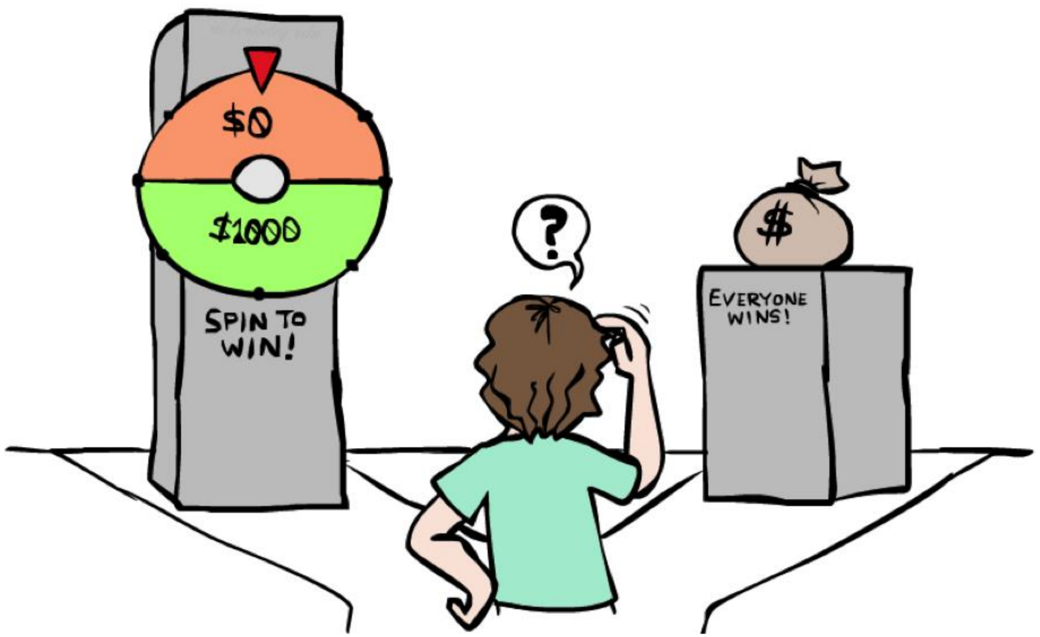

Tekintsük az alábbi nyereményjátékot:
[0.5, $1000; 0.5, $0]

- Mi a várható monetáris értéke? (500 $)

- Mi a bizonyossági egyenérték (certainty equivalent)?

Az elfogadható pénzérték a szerencsejáték helyett

- Ez 400 dollár a legtöbb ember számára
- A 100 dolláros különbség a biztosítási díj

Emberi hasznosságfüggvények

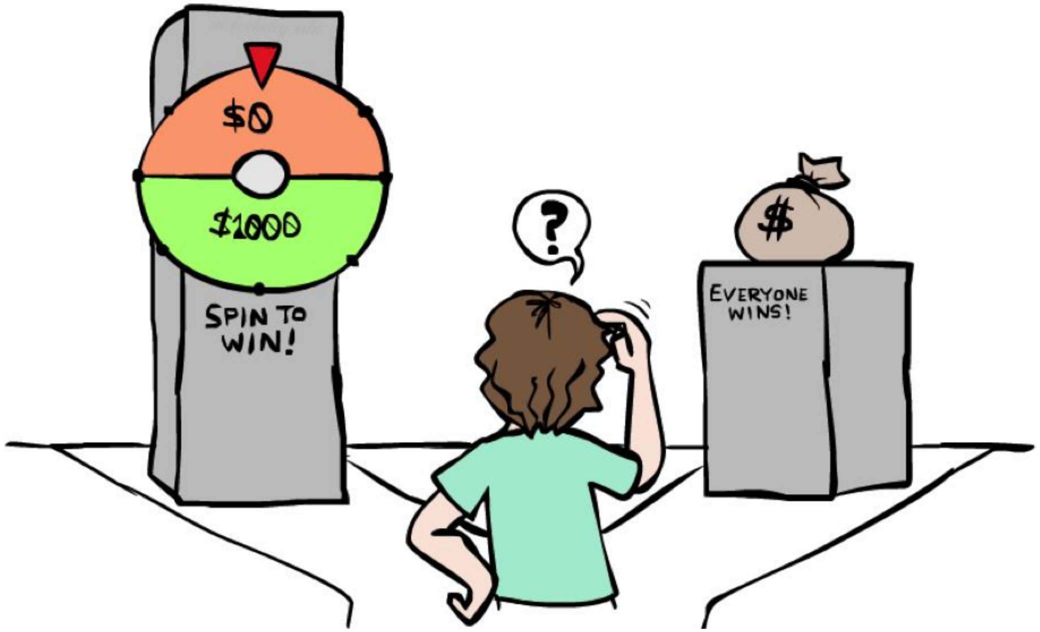

Tekintsük az alábbi sorsjátékot:
[0.5, $1000; 0.5, $0]

- Létezik a biztosítási ipar, mert az emberek fizetni fognak a kockázat csökkentésért
- Ha mindenki kockázatsemleges lenne, nem lenne szükség biztosításra!

- Win-win: az egyén inkább a 400 dollárt választja és a biztosítótársaság pedig inkább a szerencsejátékot (hasznossági görbéjük lapos és sok szerencsejátékot játszanak)