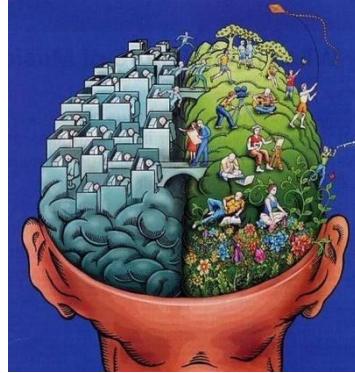




# Budapesti Műszaki és Gazdaságtudományi Egyetem Mesterséges Intelligencia és Rendszertervezés Tanszék

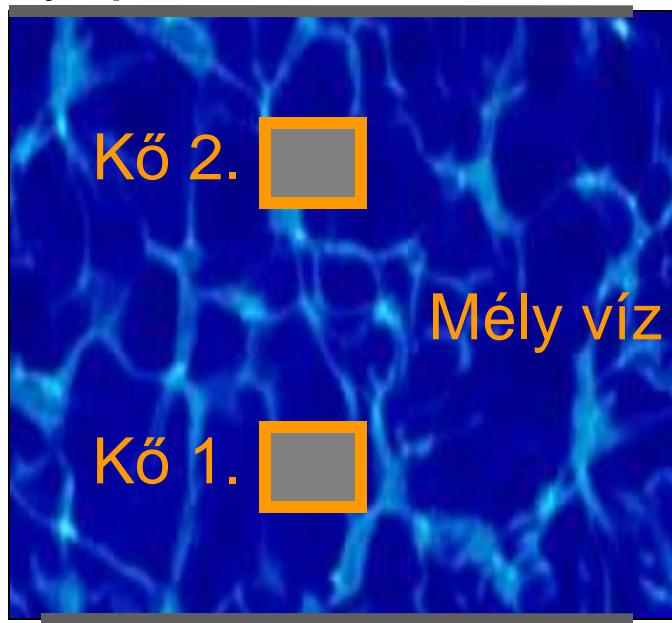


## Megerősítéses tanulás - feladatok

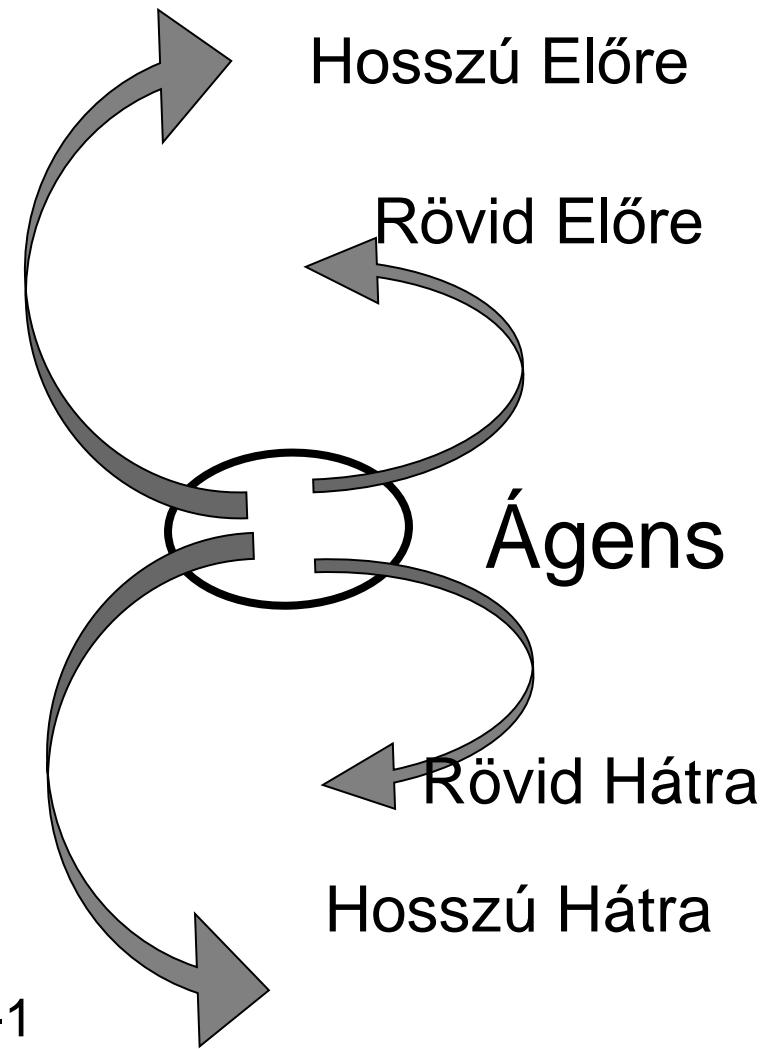
Előadó:

Dr. Hullám Gábor

## Folyópart B



## Folyópart A



Tanuló szekvencia:

RE → HE → RE → +1 (száraz lábbal át)

RE → HE → HH → HE → HH → RH → HE → -1

RE → HE → RH → -1 (megfürdött)

.....



## Part B

---

Kő 2.



$$Q(a, s) \leftarrow Q(a, s) + \alpha (R(s) + \gamma \max_{a'} Q(a', s') - Q(a, s))$$

Kő 1.



---

## Part A

### Cselekvés

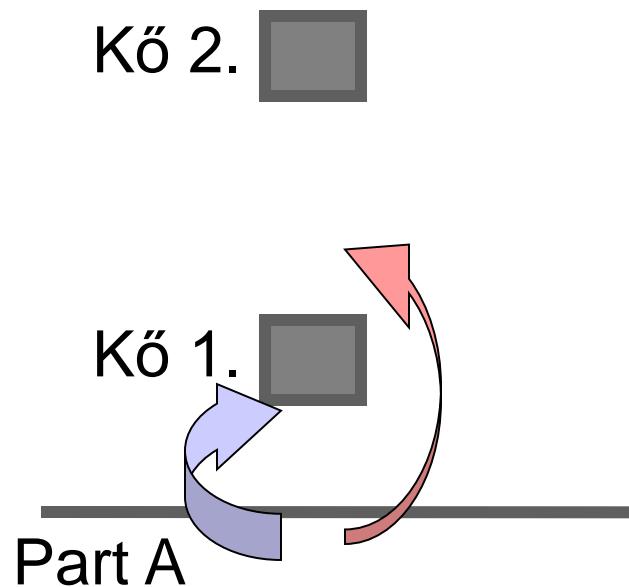
	HH	RH	RE	HE
Állapot	Part A	0	0	-0.035
	Kő 1.	-0.520	-0.550	-0.835
	Kő 2.	-0.204	-0.897	1.180
				1.158

---



## Part B

---

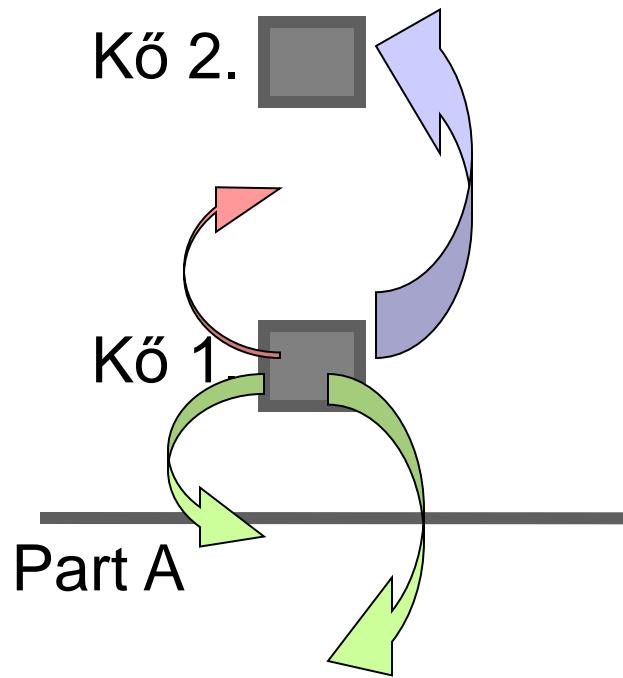


	HH	RH	RE	HE
Part A	0	0	-0.035	-0.877
Kő 1.	-0.520	-0.550	-0.835	0.555
Kő 2.	-0.204	-0.897	1.180	1.158



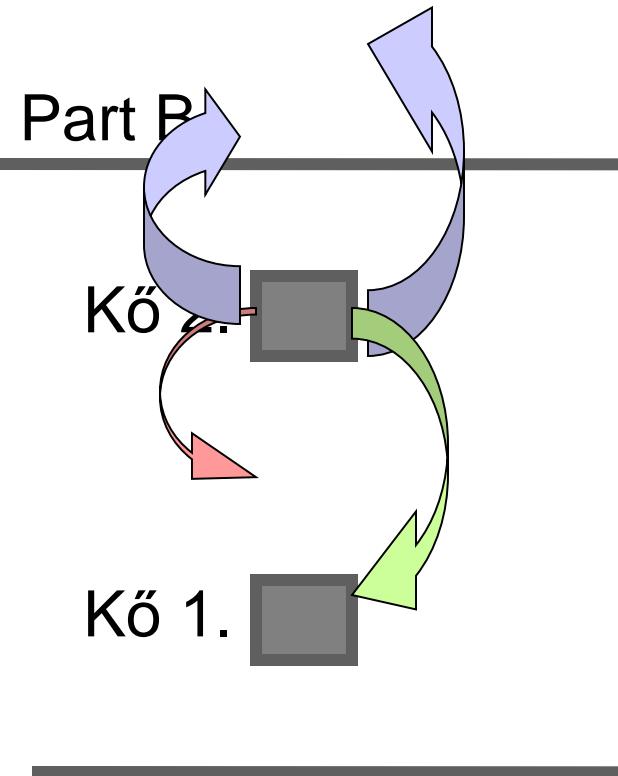
## Part B

---



	HH	RH	RE	HE
Part A	0	0	-0.035	-0.877
Kő 1.	-0.520	-0.550	-0.835	0.555
Kő 2.	-0.204	-0.897	1.180	1.158





Part A

	HH	RH	RE	HE
Part A	0	0	-0.035	-0.877
Kő 1.	-0.520	-0.550	-0.835	0.555
Kő 2.	-0.204	-0.897	1.180	1.158



# F5. Legjobb eljárás meghatározása

Aktív megerősítéses tanulást végzünk, a rendelkezésre álló cselekvések  $a_1$  és  $a_2$ , ezeket az összes

állapotban végrehajthatjuk (kivéve a végállapotot). 8 állapot van (egyszerűen az 1,2,3,...,8 sorszámokkal jelöltük őket), az állapot-átmenet mátrix az egyes cselekvések választása esetén:

$a_1$  választásakor,  $P(s \rightarrow s'|a_1)$

$$T(s, a_1, s')$$

$s \setminus s'$	1	2	3	4	5	6	7	8
1	0	0,2	0,2	0,1	0	0	0,5	0
2	0	0	0	0	0	0	0	0
3	0,5	0,1	0	0,2	0	0,2	0	0
4	0,1	0	0	0	0,1	0	0	0,8
5	0,5	0	0	0	0	0	0,5	0
6	0	0	0	0,2	0,2	0	0,2	0,4
7	0	0	0	0,3	0,2	0,5	0	0
8	0	0	0,6	0	0,2	0,2	0	0

$a_2$  választásakor,  $P(s \rightarrow s'|a_2)$

$$T(s, a_2, s')$$

$s \setminus s'$	1	2	3	4	5	6	7	8
1	0	0,2	0	0,1	0	0,2	0,3	0,2
2	0	0	0	0	0	0	0	0
3	0,1	0,4	0	0,5	0	0	0	0
4	0,1	0	0,6	0	0,1	0	0	0,2
5	0,5	0,1	0	0	0,2	0	0,2	0
6	0	0	0	0,2	0,4	0	0	0,4
7	0,1	0	0	0,3	0,2	0,2	0,2	0
8	0	0	0,4	0	0,2	0,2	0	0,2

Az állapotok valódi hasznosságértékei:

s	1	2	3	4	5	6	7	8
U(s)	+1	+20	-4	-10	0	+10	+3	5

Adja meg az adott állapotra vonatkozó optimális eljárásmódot meghatározó képletet! Mi lesz az optimális eljárásmódnak (optimális stratégiánk) az  $s=3$ -al jelölt állapotban?

# F5.Legjobb eljárás meghatározása

a1 választásakor,  $P(s \rightarrow s'|a1)$

$s \setminus s'$	1	2	3	4	5	6	7	8
1	0	0,2	0,2	0,1	0	0	0,5	0
2	0	0	0	0	0	0	0	0
3	0,5	0,1	0	0,2	0	0,2	0	0
4	0,1	0	0	0	0,1	0	0	0,8
5	0,5	0	0	0	0	0	0,5	0
6	0	0	0	0,2	0,2	0	0,2	0,4
7	0	0	0	0,3	0,2	0,5	0	0
8	0	0	0,6	0	0,2	0,2	0	0

a2 választásakor,  $P(s \rightarrow s'|a2)$

$s \setminus s'$	1	2	3	4	5	6	7	8
1	0	0,2	0	0,1	0	0,2	0,3	0,2
2	0	0	0	0	0	0	0	0
3	0,1	0,4	0	0,5	0	0	0	0
4	0,1	0	0,6	0	0,1	0	0	0,2
5	0,5	0,1	0	0	0,2	0	0,2	0
6	0	0	0	0,2	0,4	0	0	0,4
7	0,1	0	0	0,3	0,2	0,2	0,2	0
8	0	0	0,4	0	0,2	0,2	0	0,2

Az állapotok valódi hasznosságértékei:

$s$	1	2	3	4	5	6	7	8
$U(s)$	+1	+20	-4	-10	0	+10	+3	5



# F5. Legjobb eljárás meghatározása

a1 választásakor,  $P(s \rightarrow s'|a1)$

$s \setminus s'$	1	2	3	4	5	6	7	8
1	0	0,2	0,2	0,1	0	0	0,5	0
2	0	0	0	0	0	0	0	0
3	0,5	0,1	0	0,2	0	0,1	0	0
4	0,1	0	0	0	0,1	0	0	0,8
5	0,5	0	0	0	0	0	0,5	0
6	0	0	0	0,2	0,2	0	0,2	0,4
7	0	0	0	0,3	0,2	0,5	0	0
8	0	0	0,6	0	0,2	0,2	0	0

a2 választásakor,  $P(s \rightarrow s'|a2)$

$s \setminus s'$	1	2	3	4	5	6	7	8
1	0	0,2	0	0,1	0	0,2	0,3	0,2
2	0	0	0	0	0	0	0	0
3	0,1	0,4	0	0,5	0	0	0	0
4	0,1	0	0,6	0	0,1	0	0	0,2
5	0,5	0,1	0	0	0,2	0	0,2	0
6	0	0	0	0,2	0,4	0	0	0,4
7	0,1	0	0	0,3	0,2	0,2	0,2	0
8	0	0	0,4	0	0,2	0,2	0	0,2



Az állapotok valódi hasznosságértékei:

$s$	1	2	3	4	5	6	7	8
$U(s)$	+1	+20	-4	-10	0	+10	+3	5

$$U(s) = R(s) + \max_a \sum_{s'} T(s, a, s') \cdot U(s')$$

$$\frac{0,5}{P(s_1)} \cdot U(s_1) + \frac{0,1}{P(s_2)} \cdot U(s_2) + \frac{0,2}{P(s_4)} \cdot U(s_4) + \frac{0,2}{P(s_6)} \cdot U(s_6)$$

$$0,5 + 2 + -2 + 2 = 2,5$$

$$0,1 \cdot U(s_1) + 0,4 \cdot U(s_2) + 0,5$$

$$0,1 + 2 - 5 = -2$$

$$\frac{-2}{11} < 0,5$$



# F6.Q-tanulás

Egy robot Q-tanulással tanulja az optimális eljárásmódot. A robot környezete 2 db S1 és S2 állapotból áll.

Mindegyik állapotban 2 db a1 és a2 cselekvést lehet alkalmazni. A tanulási tényező (bátorsági faktor) és a leszámoltatási tényező egyformán 1/2. A robot 4 db példát dolgoz fel:

- I. (kiindulás = S1, cselekvés = a1, jutalom = 10, vége = S2)
- II. (kiindulás = S2, cselekvés = a2, jutalom = -10, vége = S1)
- III. (kiindulás = S1, cselekvés = a2, jutalom = 10, vége = S1)
- IV. (kiindulás = S1, cselekvés = a1, jutalom = 10, vége = S1)

Frissítse fel futamonként a Q-érték táblázatát (a táblázat eredetileg 0-ra legyen inicializálva). Adja meg az alkalmazott frissítési egyenletet!

Kiindulás:

	a1	a2
s1	0	0
s2	0	0

$$Q(a_1, s) = 0$$

$$Q(a_1, s_1) = 0$$

$$Q(a_1, s) \leftarrow \underbrace{Q(a_1, s)}_{0} + \gamma \max_a [R(s) + \underbrace{\gamma Q(a_1, s') - Q(a_1, s)}_{\frac{1}{2} \cdot 10}]$$

$$Q(a_1, s_1) = 0 + \frac{1}{2} (10 + 0) = 5$$

I. példa:

	a1	a2
s1	?	?
s2	?	?

$$Q(a_1, s)$$

# F6.Q-tanulás

Egy robot Q-tanulással tanulja az optimális eljárásmódot. A robot környezete 2 db S1 és S2 állapotból áll.

Mindegyik állapotban 2 db a1 és a2 cselekvést lehet alkalmazni. A tanulási tényező (bátorsági faktor) és a

leszámoltatási tényező egyformán 1/2. A robot 4 db példát dolgoz fel:

I. (kiindulás = S1, cselekvés = a1, jutalom = 10, vége = S2)

II. (kiindulás = S2, cselekvés = a2, jutalom = -10, vége = S1)

III. (kiindulás = S1, cselekvés = a2, jutalom = 10, vége = S1)

IV. (kiindulás = S1, cselekvés = a1, jutalom = 10, vége = S1)

Frissítse fel futamonként a Q-érték táblázatát (a táblázat eredetileg 0-ra legyen inicializálva). Adja meg az alkalmazott frissítési egyenletet!

Kiindulás:

	a1	a2
s1	0	0
s2	0	0

I. példa:

	a1	a2
s1	?	?
s2	?	?

$$s = s_2 \quad a = a_2 \quad \underline{s' = s_1} \quad R(s) = -10$$

$$Q(a_2, s_2) = \emptyset$$

$$Q(a_2, s_2) = \underbrace{Q(a_2, s_2)}_{\emptyset} + \gamma (R(s_2) + \max_{a'} \underbrace{Q(a', s_1)}_{\emptyset}) - \alpha$$

$$= 0 + \frac{1}{2} (-10 + (\frac{1}{2} \cdot 5)) - 0 = -3.25$$

# F6.Q-tanulás

Egy robot Q-tanulással tanulja az optimális eljárásmódot. A robot környezete 2 db S1 és S2 állapotból áll.

Mindegyik állapotban 2 db a1 és a2 cselekvést lehet alkalmazni. A tanulási tényező (bátorsági faktor) és a

leszámoltatási tényező egyformán 1/2. A robot 4 db példát dolgoz fel:

I. (kiindulás = S1, cselekvés = a1, jutalom = 10, vége = S2)

II. (kiindulás = S2, cselekvés = a2, jutalom = -10, vége = S1)

III. (kiindulás = S1, cselekvés = a2, jutalom = 10, vége = S1)

IV. (kiindulás = S1, cselekvés = a1, jutalom = 10, vége = S1)

Frissítse fel futamonként a Q-érték táblázatát (a táblázat eredetileg 0-ra legyen inicializálva). Adja meg az alkalmazott frissítési egyenletet!

Kiindulás:

	a1	a2
s1	0	0
s2	0	0

I. példa:

	a1	a2
s1	?	?
s2	?	?

$$S = S_1 \quad S' = S_1 \quad a = a_2 \quad R = 10$$

$$Q(a_2, s_1) = \underbrace{Q(a_2, s_1)}_{\emptyset} + \alpha \left[ R(s_1) + \gamma \max_{a'} Q(a', s') \right] - \underbrace{Q(a_2, s)}_{\emptyset}$$
$$10 + \frac{1}{2} \cdot 5$$

$$= \emptyset + \frac{1}{2} [10 + \frac{1}{2} \cdot 5 - \emptyset] = \underline{\underline{6.25}}$$

④  $s = s_1 \quad s = s_1 \quad a = a_1 \quad R(s) = 10$

$$Q(a_1, s_1) = 5$$

$$Q(a_1, s_1) = \underbrace{Q(a_1, s_1)}_{5} + \gamma \max_{a'} \underbrace{Q(a', s)}_{\substack{(a') \\ Q(a', s)}} - Q(a_1, s_1)$$
$$= 5 + \frac{1}{2} [10 + (2 \cdot 6, 25) - 5]$$
$$= 9,0625$$